

分类号:

密级:

U D C:

学号: 401030919007

南 昌 大 学 硕 士 研 究 生

学 位 论 文

基于 WOFOST 模型与遥感数据的油菜产量估测

**Production of agricultural forecast based on WOFOST model and
remote sensing data**

郭涛

培养单位（院、系）：数学与计算机学院 计算机科学与技术系

指导教师姓名、职称：唐荣欣 研究员

指导教师姓名、职称：汤文超 讲师

申请学位的学科门类：工学

专业领域名称：计算机科学与技术

论文答辩日期：2022 年 5 月 22 日

答辩委员会主席：_____舒坚_____

评阅人：_____

2022 年 5 月 26 日

摘 要

遥感技术兴起于上世纪六十年代,随着时代的发展遥感技术也在逐步发展和完善。卫星所获取的数据也在不断的更新,现今遥感卫星数据有着很高的精准度,这高精度的数据使得遥感技术能够在农业、水域、环境、资源保护、水文、气候、地质等领域开花,进一步的推动着我国的发展。

粮食是一个国家的重要资源,纵观我国历史,我国从古自今一直是一个农业大国。我国南部有着世界三大流域之一的长江,得天独厚的地理条件是国的粮食种植生产的良好基础。我国的粮食产量虽然高,但由于我国的人口众多,粮食问题依然是我国的一个重要问题。所以针对粮食的产量预测就显得非常重要。准确的预测粮食的产量对我国的粮食安全、作物种植的结构化调整、粮食的进出口贸易对策制定都有这十分重要的意义。就目前来说,对于大尺度区域产量估测主要依靠的遥感技术。遥感卫星数据容易被气候环境所影响,图像数据质量会受云层和其他因素的影响,使得多数数据无法使用。所以现今的大多数估产方法都是基于单时期的遥感数据,单时期的遥感数据无法对作物的生长状态进行一个完整反映,估产方法存在一定的局限性。本文是基于遥感数据与 WOFOST (World Food Studies) 模型(植被生长模型)对多时期湖北省油菜进行产量估测的研究,内容如下:

(1) 油菜产量估测实现的重要基础是产量模型的建立。本实验为获得较为精准的产量模型,对华中农业大学作物实验基地的实验实测数据进行数据分析建模,获得了油菜 LAI 与产量的关系建模。

(2) 油菜生长过程 LAI 的变化有着较强的依赖性,但油菜时序 LAI (叶面积指数) 数据获取难度较大。本实验采用 WOFOST 模型结合日值气象数据同化模拟获得油菜生长过程中的 LAI,模拟的 LAI 时序与 modis LAI 进行拟合比对,保证模拟 LAI 时序曲线与 modis LAI 时序曲线变化曲线一致。通过遥感数据对模型进行同化能使得油菜模拟结果与实际油菜生长数据保持一致。

(3) 大尺度区域的产量估测能实现最终依靠的是高精度的遥感数据。大尺度区域产量估测的实现是基于产量估测模型以及遥感数据与作物生长状态相关模型,本实验使用遥感数据是高分一号卫星数据。通过对多时期高分数据与多

时期 LAI 结合建模得出 GF-1 数据估测油菜 LAI 模型。

（4）油菜 LAI 的提前预测有利于作物的产量的预测，以及对油菜种植策略的调整，提高生产量。为实现对油菜 LAI 的提前预测，在此我们使用了长短记忆神经网络（LSTM）模型对其进行 LAI 时序曲线进行模拟进而预测某一时间段后 20 天的 LAI。通过提前获取的 LAI 可以进一步的提前对油菜产量进行预测。

关键词：WOFOST 模型；MODIS；LAI 时序曲线；GF-1；油菜产量估测；LSTM

ABSTRACT

Remote sensing technology emerged in the 1960s. With the development of the times, remote sensing technology is also gradually developed and improved. The data obtained by satellites is also constantly updated. Today's remote sensing satellite data has high accuracy. This high-precision data enables remote sensing technology to blossom in the fields of agriculture, waters, environment, resource protection, hydrology, climate, geology, etc. Further promote the development of our country.

Food is an important resource of a country. Throughout our history, our country has been a major agricultural country since ancient times. The southern part of our country has the Yangtze River, one of the three major river basins in the world. The unique geographical conditions are a good foundation for the country's grain production. Although my country's grain output is high, the grain problem is still an important issue in my country due to its large population. Therefore, the forecast of grain output is very important. Accurate prediction of grain output is of great significance to my country's grain security, structural adjustment of crop planting, and formulation of grain import and export trade countermeasures. For now, the remote sensing technology is mainly used for large-scale regional production estimation. Remote sensing satellite data is easily affected by the climate environment, and the quality of image data is affected by clouds and other factors, making most data unusable. Therefore, most of the current yield estimation methods are based on single-period remote sensing data. Single-period remote sensing data cannot fully reflect the growth status of crops, and yield estimation methods have certain limitations. This article is based on remote sensing data and WOFOST model (vegetation growth model) to estimate the yield of rapeseed in Hubei Province for multiple periods. The content is as follows:

(1) The important basis of rape yield estimation is the establishment of yield model. In order to obtain a more accurate yield model, this experiment analyzed and modeled the experimental data of the crop experimental base of Huazhong Agricultural University, and obtained the relationship model between rape Lai and

yield.

(2) There is a strong dependence on the change of Lai in the growth process of rape, but it is difficult to obtain the temporal Lai (leaf area index) data of rape. In this experiment, WOFOST model combined with daily meteorological data assimilation simulation is used to obtain Lai in the process of rape growth. The simulated Lai time series is fitted and compared with MODIS Lai to ensure that the simulated Lai time series curve is consistent with the change curve of MODIS Lai time series curve. Assimilating the model through remote sensing data can make the simulation results of rape consistent with the actual rape growth data.

(3) The yield estimation of large-scale region can be realized ultimately by relying on high-precision remote sensing data. The realization of large-scale regional yield estimation is based on the yield estimation model and the correlation model between remote sensing data and crop growth state. The remote sensing data used in this experiment is gaogao-1 satellite data. Through the combination of multi period high score data and multi period Lai modeling, the GF-1 data estimation rape Lai model is obtained.

(4) The advance prediction of rape Lai is conducive to the prediction of crop yield, the adjustment of rape planting strategy and the improvement of production. In order to predict the Lai of rape in advance, we use the long and short memory neural network (LSTM) model to simulate the Lai time series curve, and then predict the Lai 20 days after a certain period of time. The Lai obtained in advance can further predict the rape yield in advance.

Key Words: WOFOST model; MODIS; LAI time series curve; GF-1; Canola yield estimation; LSTM

目 录

摘 要	I
ABSTRACT	III
第 1 章 绪论	1
1.1 选题背景及研究意义	1
1.2 国内外研究现状	3
1.3 论文的主要内容	5
第 2 章 基于地面实验预测油菜产量	7
2.1 试验数据	7
2.1.1 研究区域	7
2.1.2 数据采集	8
2.2 油菜不同生长期 LAI 与产量关系	9
2.3 本章小结	10
第 3 章 基于 WOFOST 模型的地面连续 LAI 数据同化	11
3.1 WOFOST 作物生长模型	11
3.2 WOFOST 模型相关数据及处理	12
3.2.1 数据类型	12
3.2.2 逐日气象数据	12
3.2.3 基于 MODIS LAI 的 LAI 时序曲线提取	14
3.2.4 实验区域油菜 LAI 实测数据	15
3.3 WOFOST 模型的建立	16
3.3.1 同化与呼吸作用	17
3.3.2 作物生长过程与土壤水平衡	18
3.3.3 作物的干物质积累与分配	19
3.3.4 LAI 叶面积模拟	20
3.4 WOFOST 模型与遥感数据同化	21
3.4.1 General 与 Crop 模块参数设定	21
3.4.2 Weather 与 Time 模块参数设定	22

3.4.3 Soil 与 Reruns 模块参数设定	22
3.4.4 WOFOST 同化结果	23
3.5 本章小结	25
第 4 章 基于高分一号卫星数据的油菜产量估计	26
4.1 高分一号数据准备	26
4.2 基于高分影像的大区域尺度 LAI 提取方法	26
4.3 基于高分一号影像的作物产量估算模型	32
4.4 本章小结	32
第 5 章 基于湖北省的估测方法验证	33
5.1 用于模型验证的数据准备	33
5.2 基于深层卷积神经网络的地物提取	34
5.3 基于金字塔瓶颈残差网络的高分一号数据分类	36
5.3.1 金字塔残差网络	36
5.3.2 基于多光谱高分图像数据的金字塔残差网络	37
5.4 基于多光谱图像分类结果分析	39
5.5 算法验证	40
5.6 结论分析	42
5.7 本章小结	42
第 6 章 LSTM 对油菜 LAI 生长时序曲线的预测	43
6.1 长短记忆神经网络 (LSTM) 与循环神经网络 (RNN)	44
6.1.1 循环神经网络	44
6.1.2 长期依赖问题	45
6.1.3 长短期记忆神经网络 (LSTM)	47
6.2 叶面积指数 (LAI) 的预测	49
6.3 长短期记忆神经网络的参数调优	50
6.4 LAI 预测精准度分析	50
6.5 本章小结	52
第 7 章 总结和展望	53
7.1 本文工作总结	53
7.2 未来工作展望	54

目录

致 谢	55
参考文献	56
攻读学位期间的研究成果	61

第 1 章 绪论

1.1 选题背景及研究意义

我国是一个人口大国，根据第七次全国人口普查显示我统计人口有 14 亿 4 千 3 百多万。因为人数总多，所有我国的粮食供给是一个必须要解决的问题。油菜作为我国的主要粮食之一，它的地位是不可置否的。得利于农业的高速发展，我国的油菜产量呈增加趋势。

在大区域尺度实现快速、精确的作物产量估测，对我国制定粮食政策，进行粮食价格宏观调控^[1]，实现乡村经济的振兴^[2]以及进出口贸易等都具有重要意义。与传统费时、费力、仅适用于小区域的农学预报^[3]、统计预报^[4]、气象统计^[5]相比，具有宏观、动态和快速等特点遥感技术为作物长势监测^[6]、产量预测提供了新的手段和方法。

从全世界角度审视油菜，不难发现油菜是应用最广泛的粮食之一，在世界人口爆炸的新世界，油菜供养着世界近一半的人口。针对这种现状，油菜在日常生产中有着非凡的地位。为满足各地对油菜的供应，就需要对油菜做出相应的政策。在贸易上制定合理安排采购计划，在生产上，对油菜进行合理的农业生产指导^[7]。

为保证油菜在市场上的流通，我们需要针对性的对当年油菜的产量有一个预测。各级政府能够通过油菜产量的预测来对农业经济政策进行调整。油菜的产量的有效预测将为社会农业决策^[8]提供依据，是发挥作物潜力价值的重要途径，可以科学准确的评估某区域的农业生产系统^[9]，为农业资源的科学开发、农业规划提供重要的指导建议。

植被生长模型虽然一定程度上能对作物的生长状态有一个较好的呈现，但通过对模拟数据与各地区实际作物生长数据的对比不难发现，模拟数据与真实数据点拟合性较差，这可能是由于作物的生长环境的不用造成的。本课题使用的植被生长模型是 WOFOST 模型，为了提高作物模拟数据的精准度，模型结合遥感数据进行了作物的同化。

传统的作物产量统计方法是通过对实地数据的测量获得的。传统方法对作物产量统计的准确性有一定的保障，但是无法对产量有前瞻性。现如今信息化

社会对农业经济有着巨大的冲击，传统的产量测算无法满足现代化社会的要求。信息化社会对于信息的获取至关重要。近年来，遥感技术日渐成熟。遥感技术为产量预测提供了新方法。

WOFOST (World Food Studies) 模型模拟作物生长的主要过程是物候发育、CO₂ 同化、蒸腾作用、呼吸作用、干物质积累和分配等。这种以农学模型为基础的估产方法能很好地描述作物的发育情况，但通常需要大量输入参数，数据获取难度高。目前结合作物生长模型和遥感观测的各自优势，利用时空连续的卫星观测数据以及气象等辅助数据通过数据同化的方法将遥感信息融合到作物生长模型中，遥感估产的新研究方向^[10]。

相较于传统的产量预测，基于遥感对产量的预测，能够很好的降低成本^[11]，并且能作用于更大的时空覆盖范围。大区域的产量预测必须是要通过遥感进行的。但针对遥感对大区域产量预测实验中有着总多的困难。经过众多研究表明，产量与 LAI 有着极其紧密的联系。这便引出了遥感产量估测的第一个重要问题，遥感图像与 LAI 的相关建模。遥感与 LAI 的对应关系建模需要遥感数据与 LAI 有一个明确的对应关系，实际上 LAI 的时序曲线数据获取难度较高，这是遥感大区域估产的第二个问题。如何将遥感关联 LAI 即模拟 LAI 时序数据与实际 LAI 时序数误差减小，这是大区域产量预测的第三个问题。

通过遥感影像可以对其进行 NDVI、EVI2、SR (比值植被指数)、VARIGreen、EVI、MSAVI (改进型调整植被指数) 等指数的提取。这些指数很好的展现作物的生长状况，这给油菜产量的预估提供了切实可行的基础。油菜面积的获取至关重要。本次研究采用的是金字塔残差瓶颈网络^[12]，对油菜生长过程中的高分影像进行分类，从而获得油菜种植面积。

当前的产量预测中，只能针对当前数据对作物产量进行预测，但实际生产过程中，需要对作物产量有一个更具前瞻性的分析。LAI 数据与产量数据有着极其密切的联系，一定程度，作物的 LAI 的数据是对作物最终产量的一个侧面体现。作物 LAI 的预测不仅可以对其产量进行预测，而且可以通过对预测 LAI 反向调整作物种植策略。通过调整种植策略达到增加产量的作用。长短记忆神经网络 (LSTM) 是 Hochreiter 和 Schmidhuber 在 1997 年首次提出的。LSTM 在经过众多人的不断精炼与提升后，LSTM 被广泛应用于各类场景。LSTM 通过对时序数据的处理能够很好的应用于各行各业的数据预测领域中，例如对股票信息

的预测、对网络攻击的检测、对电力系统中的电力预测等。总多试验表明，长短记忆神经网络在时序数据预测上面有这其较高的精准度，本实验运用长短记忆神经网络对作物生长 LAI 进行模拟预测，在获取当前作物生长状态 LAI 来对作物的未来一段时间内的生长状态做预测。实验证明 LSTM 能够对作物 LAI 时序数据进行一个较为精准的预测。

在经济全球化的今天，商业贸易是让国家经济发展的重要途径之一。油菜作为基础粮食，在进出口贸易有着无可替代的地位。油菜的有效出产与种植规划，国家政府制定即时有效的粮食政策，以及市场针对油菜的决策，都需要对油菜产量有一个前瞻性的预测。

油菜是我国温带地区的主要经济作物之一，其副产品可用于食品、生物燃料和医药等方方面面^[13]。它有不同的发育阶段（如苗期、抽薹期、开花期、荚果期），这些阶段光谱各不相同，特别是在开花期，整个冠层出现明显的黄色花朵，这种生长发育特点增加了通过植被指数模型预测产量的不确定性。本研究旨在探索如何利用有限的地面观测数据，进行大区域范围的油菜产量估测，主要包括：

针对油菜 LAI 与产量关系进行数学建模；

（1）使用 WOFOST 模型对油菜进行生长模拟，获取各地本地化的 LAI 时序数据。

（2）通过对遥感数据与 LAI 数据以及产量关系模型构建遥感估测模型；

（3）通过高精度的油菜提取算法估算县、市域尺度的油菜产量，并验证算法的正确性；

1.2 国内外研究现状

技术的不断革新，现今的油菜生长状况能通过油菜生长模型与气象站点的气象数据来对油菜进行有效的模拟。现今，油菜生长模型使用比较多的是 ORYZA2000^[14]、APSIM^[15]、WOFOST。但是，油菜生长模型所需要的数据要求比较高，部分数据难以获取，但模型的模拟需要获得完整数据才能对油菜的整个生长状态进行模拟。

传统的产量预估模型有：经验模型^[16, 17]，半经验模型。但随着遥感技术的不断成熟，遥感技术能够很好地应用到农业产量预测领域。通过遥感估产的方

法主要有两种，一种是半经验方法，主要是建立遥感数据与作物产量间的经验模型。赵文亮等基于 MODIS-NDVI 数据通过分析河南省 18 个地市冬小麦产量、播种面积的时间变化特征，建立了冬小麦估产模型，平均相对误差小于 7%^[18]。吴琼等通过在大豆不同生长期测定地上部生物量和叶面积指数与对应的高光谱数据构建经验模型^[19]，实验表明综合三个生长期的估产模型效果最优。Maresma, A. 等利用无人机获取玉米的光谱信息构建了与产量和施氮水平的估产模型^[20]，结果表明 WDRVI 指数效果最好。这种通过经验模型进行的估产方法，模型简单，应用方便快捷，但往往只适用于建模的区域，难以推广应用于其他区域。另一种方法以遥感数据为输入参数，通过作物生长模型模拟作物产量。作物生长模型是根据一系列作物参数、土壤数据、作物管理数据以及气象数据，运用数学模型定量化的描述作物光合生产、呼吸、蒸腾、干物质生成与分配等机理过程，同时考虑了大气-植被-土壤之间的交互作用^[21]。根据作物生长过程的主要驱动因子，可将作物模型分为：光能驱动模型（CERES 模型，APES 模型）、土壤水分驱动模型（AquaCrop 模型^[22]，SWAP 模型^[23]，等）、大气 CO₂ 驱动模型（SUROS 模型，WOFOST 模型）和综合因子驱动模型（DSSAT 模型^[24]，APSIM 模型）^[25]。其中 WOFOST 模型在遥感作物估产研究中广为应用。WOFOST 模型是由世界粮食研究中心（CWFS）和荷兰瓦赫宁根大学共同开发^[26]，已广泛应用于产量预测^[27]、气候变化观测^[28]和遥感数据同化^[29]等方向。

遥感数据的获取是通过卫星通讯工具搭载的多光谱以及可见光的摄像头，对地表拍摄获取遥感图像。早在上世纪 70 年代，遥感技术就已经渐渐出现在人们眼前了。经过长达半个世纪的发展，遥感技术已经十分成熟了，遥感技术已经渗透其他的技术领域了。在作物产量预测技术，遥感技术在其上的方法大致有 3 种，机理模型，半经验半机理模型^[30]，以及经验模型。由于叶面积指数（LAI）的时序曲线与产量结果有着巨大的相关性，所以很多产量预测都用到了植被生长 LAI 时序曲线。LAI 时序曲线估测，采用了卡尔曼算法^[31]。结合植被各个生长时期的 LAI 和作物模型获取的 LAI 时序曲线，进行演算，获得产量关系表达式，从而对作物进行产量估测。通过遥感图像数据可以反演获得 LAI 值。进一步从遥感图像数据到产量的反演。

早在上世纪 80 年代，我国就进入对遥感领域，发展至今遥感技术已经得到了很好的完善。通过对遥感图像的处理我们可以得到一系列的植被指数。通过

这些植被指数我们能很好的对作物产量进行估算^[32]。例如 NDVI（归一化植被指数）与 LAI（叶面积指数）与产量都有着巨大的相关性。

美国打开了遥感技术的大门。美国在很早就开始了遥感技术对作物产量的估量预测。以遥感数据涵盖面积广的特点能对世界许多国家的粮食产量进行预测，对世界粮食市场的发展有一个大概的了解，从而进一步针对粮食市场进行调节。产量预测能够确保美国的粮食市场保持优势。在上世纪 70 年代，美国已经能实现对全国的遥感产量估测，且其遥感估产技术精准度非常之高效。在初尝成果后，美国更为重视遥感技术。

不仅仅是美国，加拿大也在利用遥感数据辅加其他数据对作物产量进行产量估计。

欧洲的大多数国家也在使用遥感技术对作物产量进行估测，欧盟利用 SPOT 数据对做作物面积估测，再通过 MODIS 数据与作物生长模型建立产量模型^[33]。

早在上世纪 80 年代初期，遥感就在我国开始兴起。早在 1982 年我国就利用遥感数据对小麦进行过估产^[34]。在此之后遥感在我国迎来了高速发展的时期。遥感数据与气象数据的结合使得农业有了很大的进步。农业遥感也由此诞生。

早在“六五”计划^[35]开始，我国针对卫星遥感技术对作物产量估产的研究就从未中断过，并持续的在众多地区已经多种作物上进行了实验。国家气象局更是在 1987 年针对北方的 11 个城市的小麦进行了产量估计^[36]。在此处实验中，国家气象局通过此次的实验探索出了一种产量估测模型，结合模型开发了一种产量估测系统，它可将气象数据与实测数据进行结合从而获得较为准确的产量估测数据。该系统自 1985 至 1989 年间，为众多的地区进行产量估测，在这 4 年中预计给国家降低的粮食损失约 33 万多吨。在 1992 年至 1996 年之间，我国就河北、山东、河南、安徽等各地的作物进行作物生长监测与预报^[37]。通过长达 40 年的发展，遥感技术已经可以很好的作用于农业产量估测上了。

1.3 论文的主要内容

（1）基于地面试验预测油菜产量建模

在大区域尺度实现快速、精确的作物产量估测对我国粮食安全、作物种植结构调整、进出口贸易等具有重要意义。遥感技术的发展为农业估产领域带来了新的技术和手段。以湖北省油菜为研究对象，针对如何利用有限的地面观测

数据，进行大区域范围的油菜产量估测的问题，采用结合遥感数据和气象数据，通过 WOFOST 模型进行数据同化，模拟油菜生长过程中的 LAI（叶面积指数）变化，提取油菜关键生长期 LAI，以弥补在大区域尺度数据的不足；之后通过 LAI 作为中间量构建了基于 GF-1 WFV 数据的大区域尺度油菜估产算法。研究发现，油菜抽薹期和花期的综合 LAI 能够实现准确、提前的油菜产量预估，在抽薹期 SR 植被指数与 LAI 相关性最好，在花期则是 VARIgreen（可见光大气阻抗植被指数）植被指数。

（2）基于 WOFOST 模型的地面连续 LAI 同化

通过每日对油菜作物的监测可以获得作物 LAI 时序数据，但作物生长周期过长，数据获取难度较大。为获取到油菜 LAI 时序数据，本试验采用了作物生长模型对油菜进行模拟生长。模拟模拟结合实测数据以及遥感数据，实现了对作物的同化。使得模拟数据与实际数据拟合度较高。通过模型模拟的 LAI 数据接近真实作物生长 LAI。

（3）基于遥感数据的油菜产量估测

油菜产量的建模以及 WOFOST 模型对油菜生长的模拟为基于遥感数据的油菜大面积估产提供了实验基础。油菜的大面积产量预测还需要对遥感数据与产量的关系进行建模。油菜产量的预测是基于产量与 LAI 的相关性建模成功的，为实现对遥感数据到产量的建模，实验将遥感数据与 LAI 先一步进行分析建模，获取遥感图像到 LAI 的建模模型。结合产量与 LAI 的模型以及油菜生长面积的估测，实现对油菜的大面积估产。

（4）针对湖北省部分区域的产量预测对实验模型预测

实验对湖北省部分区域进行油菜产量预测，通过对预测数据与湖北省年鉴统计数据对比，通过对比结果来对实验算法进行验证。

第 2 章 基于地面实验预测油菜产量

在大区域尺度实现快速、精确的作物产量估测对我国粮食安全、作物种植结构调整、进出口贸易等具有重要意义。遥感技术的发展为农业估产领域带来了新的技术和手段。以湖北省油菜为研究对象，针对如何利用有限的地面观测数据，进行大区域范围的油菜产量估测的问题，采用结合遥感数据和气象数据，通过 WOFOST 模型进行数据同化，模拟油菜生长过程中的 LAI（叶面积指数）变化，提取油菜关键生长期 LAI，以弥补在大区域尺度数据的不足；之后通过 LAI 作为中间量构建了基于 GF-1 WFV 数据的大区域尺度油菜估产算法。研究发现，油菜抽薹期和花期的综合 LAI 能够实现准确、提前的油菜产量预估，在抽薹期 SR 植被指数与 LAI 相关性最好，在花期则是 VARIGreen（可见光大气阻抗植被指数）植被指数。最终通过高分影像的 LAI 建模对大区域油菜产量进行估测。

2.1 试验数据

2.1.1 研究区域

湖北是油菜种植大省，通过年鉴可知湖北油菜年产量都在 210 万吨以上。湖北省位于我国中部，地跨东经 $108^{\circ}21'42'' \sim 116^{\circ}07'50''$ 、北纬 $29^{\circ}01'53'' \sim 33^{\circ}6'47''$ ，大部分地区为亚热带季风气候，雨量充足，气候适宜，有着非常好的油菜种植优势。本研究将在湖北省黄石市阳新县、武穴市开展县域尺度的油菜产量估测。

图 2.1 为武穴市研究区域样例图，表 2.1 为湖北省实验点具体信息

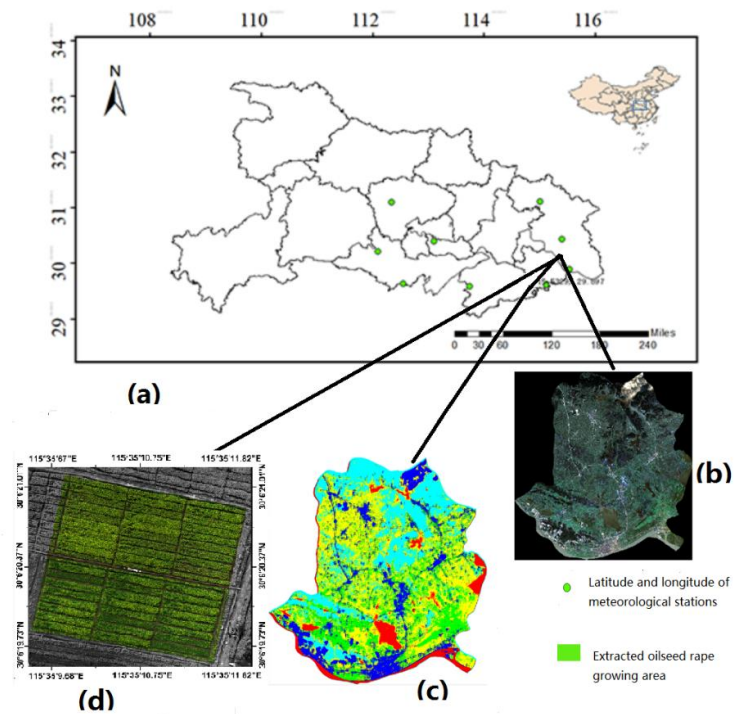


图 2.1 实验区域（武学市）（a）湖北气象站点（b）武穴高分数据（c）武穴市分类（d）实测 LAI 区域

表 2.1 研究区域以及地理位置

研究区域	地理位置
钟祥	N31°6'00", E112°20'24"
麻城	N31°6'36", E115°0'36"
荆州	N30°12'36", E112°5'23"
监利	N29°30'00", E112°32'24"
嘉鱼	N29°35'24", E113°33'00"
阳新	N29°30'36", E115°7'11"

2.1.2 数据采集

在本研究中，叶面积指数（LAI）由 LAI-2200C 植物冠层分析仪确定。在

油菜的4个关键生长期，对所有48个油菜区块进行LAI测量，每个区块测量6次，取平均值作为区块的LAI。油菜小区于2015年5月5日收获，在每个区块中，切割了一半的地上植物材料（约15平方米），用以对最终产量进行破坏性测量，地块产量计算为种子总重量与地面面积的比值（kg/ha）。

2.2 油菜不同生长期 LAI 与产量关系

根据已有研究基础，油菜在旺盛生长时期的LAI与最终的产量存在着一定的关联，因此，我们对油菜四个不同生长期地面LAI测量数据与产量进行相关性分析，结果如表2.2所示。从表2.2中可以发现油菜抽薹期和荚果期的LAI与产量密切相关，决定系数（ R^2 ）高于0.7，苗期LAI与产量之间的相关性较低。由于荚果期LAI的值是由油菜冠层荚果贡献的，而荚果的量直接决定了油菜最终的产量，所以荚果期LAI与产量相关性最高（ $R^2=0.84$ ），但在这个时期进行油菜产量评估已经太晚，距离收获时间大约仅有一个月。此外抽薹期和开花期综合的LAI与产量之间存在显著关系，这是因为在抽薹期，油菜正处于旺盛的生长时期，具有几乎最大的植物绿度和光合能力，表征着油菜的潜在产量。在花期虽然油菜花在冠层呈现明显的亮黄色，一定程度上混淆了花和叶子的光谱影像最终的相关性，但花的数量与最终荚果的数量直接相关[21]。因此，为了达到提前准确预测产量的目的，我们采用逐步回归的方法，利用抽薹期和开花期的LAI构建模型：

$$Y_{\text{ield}} = 581.82 * LAI_{\text{boltingstage}} + 91.47 * LAI_{\text{FloweringStage}} - 63.10 \quad (2.1)$$

Yield 为最终油菜产量，LAI Bolting Stage 为抽薹期油菜 LAI 值，LAI Flowering Stage 为花期油菜 LAI 值。

表 2.2 油菜四个生长期叶面积指数（LAI）估算产量的决定系数（ R^2 ）和标准误差（SE）

	苗期	抽薹期	花期	荚果期	抽薹期+开花期
R ²	0.21	0.70	0.59	0.84	0.72
SE	764	475	561	352	424

从以上实验分析可知，利用遥感手段实现提前准确预测油菜产量，LAI 值可

以作为一个关键量。

通过对实测数据进行 LAI——产量的建模我们可以得出的模型以下；

$$Yield = 581.82 * Lai_{抽薹期} + 91.47 * Lai_{花期} \quad (2.2)$$

其中 $Lai_{抽薹期}$ 为油菜抽薹期 LAI, $Lai_{花期}$ 为油菜花期 LAI。

2.3 本章小结

本章是对油菜产量模型的构建。实验通过对实测数据的分析建模获得了较为精准的基于 LAI 到油菜产量的模型。较为精准的油菜产量模型是大尺度区域油菜产量估测的基石。

第 3 章 基于 WOFOST 模型的地面连续 LAI 数据同化

作物生长过程时间较长, 时序 LAI 数据获取过程繁杂, 作物 LAI 时序数据获取难度过大。作物生长模型的出现很好的为其提供了解决办法。但作物生长环境的不同会导致作物生长状态及相关参数的不同, 不同地区的作物的 LAI 曲线各有不同, 为保证作物生长模型模拟的数据与本地的同化, 实验通过比对遥感数据与部分实测数据对作物生长模型进行同化。本实验采用的作物生长模型是 WOFOST 模型。

3.1 WOFOST 作物生长模型

WOFOST 增长模型是由世界食品研究中心 (CWFS) 和荷兰瓦赫宁根大学开发的动态解释模型 (van Ittersum 等, 2003)。它已广泛用于产量预测 (Supit 等, 2012 年)、气候变化 (Lecerf 等人, 2019 年) 和遥感数据同化 (Huang 等, 2019 年)。在 WOFOST 中, 根据生态生理过程模拟作物生长^[38]。主要过程是物候发育、CO₂ 同化、蒸腾作用、呼吸作用、同化物分配到各个器官和干物质形成。WOFOST 的物候由无量纲状态变量发展阶段 (DVS) 描述。对于大多数一年生作物, 幼苗出苗时 DVS 设置为 0, 出苗时 (谷物) 设置为 1, 成熟时设置为 2。WOFOST 通常用于模拟在潜在条件 (最佳供水) 和缺水 (可用水限制潜在生产) 条件下的作物生长 (de Wit 等, 2019 年)。WOFOST 模型的详细原理和具体应用在 WOFOST 7.1 用户手册 (Boogaard et al., 2014) 中有描述。

WOFOST 是一个通用的基于过程的模型, 可以模拟 22 种作物每天的生长, 但不包括蔬菜和果树。26 作物生长的模拟过程数据, 例如, 物候发育、CO₂ 同化、蒸腾、呼吸、分配在土壤、气象、水管理和农学管理等条件下, 同化物的各种器官和干物质形成。WOFOST 包括作物生长模拟的不同配置: 潜在生产模拟 (受作物品种、辐射和温度限制)) 和水和养分受限情况 (养分和/或水短缺限制作物生长)。在本研究中, 考虑了养分受限生产的配置。模型描述的更多细节可以在早期的研究中找到。在这项研究中, 我们使用 WOFOST 模型来模拟长江中单稻、早稻、小麦、玉米、豆类、棉花、油菜籽和马铃薯的氮吸收。

3.2 WOFOST 模型相关数据及处理

3.2.1 数据类型

WOFOST 模型所需数据包含有 MODIS LAI 数据、逐日气象数据、实验地区油菜实测 LAI 数据。

WOFOST 模型所需的每日气象数据来自于中国气象数据网 <http://data.cma.cn>。WOFOST 模型输入的气象参数有日最高温度、日最低温度、平均气压、日平均风速、日总辐射、降雨量。

WOFOST 模型的同化辅助数据是 MODIS LAI 数据、地面油菜实测 LAI 数据。MODIS LAI 数据 lai 源于 NASA(<https://ladsweb.modaps.search/>)。油菜地面数据来源于湖北省武穴市华中农业大学作物实验基地的油菜种植实测 LAI 数据。

3.2.2 逐日气象数据

本次研究所选用的气象站点数据有荆州、嘉鱼、麻城、天门、监利、钟祥、阳新、江夏天。样本数据实例如表 3.1 所示；

逐日气象数据由于数据量较大，容易出现数据缺失或数据乱码情况。本次实验中我们对缺失的气象数据进行插值处理，本实验采用的插值方法是多项式插值法^[39]。

WOFOST 模型输入的气象参数有日最高温度、日最低温度、平均气压、日平均风速、日总辐射、降雨量。逐日气象数据中不含有日总辐射。日总辐射数据的获取可通过对逐日气象数据中的日照时长进行转换^[40]。

$$R_s = R_{\max} (a_s + b_s * \frac{n}{n_r}) \quad (3.1)$$

式中 R_s —— 太阳总辐射 (MJ / m^2)

R_{\max} —— 天文辐射 (MJ / m^2)

a_s 、 b_s —— 与大气状况相关的经验系数，分别取 0.25、0.5

n —— 日照时长 (h)

WOFOST 模型模拟参数输入：对气象数据进行格式整合（WOFOST 输入特定格式），导入数据。

表 3.1 2017 年前 30 天嘉鱼县气象站数据信息

年	天数	最低温度	最高温度	平均压强	日照时长	降雨量	平均风速
2017	1	5.2	9.8	10152	1.9	0	15
2017	2	6.7	8.6	10158	2.5	3.7	14
2017	3	3.3	6.7	10202	3.2	13.5	13
2017	4	-0.3	3.3	10187	3.6	35.1	16
2017	5	-1.2	1.3	10192	2.3	0	29
2017	6	1.1	2.5	10140	3.2	4.4	24
2017	7	-0.7	1.7	10152	2.8	1.3	24
2017	8	-0.5	7	10210	3.4	0.1	22
2017	9	-2	10.1	10217	4.2	0	22
2017	10	-1.3	10.7	10237	2.2	0	27
2017	11	-1.2	10.8	10253	2.8	0	20
2017	12	-2	9.2	10257	3	0	16
2017	13	0.5	8.8	10212	2.6	0	23
2017	14	2	13.8	10165	2	0	28
2017	15	3.4	10.4	10126	1.5	0	23
2017	16	5.8	9	10115	1.7	2.2	25
2017	17	4.9	12	10115	2.1	0	9
2017	18	4	9	10152	2.6	0	17
2017	19	4.8	7	10175	1.8	2.8	20
2017	20	5.2	7.7	10148	0.7	3.8	25
2017	21	6.1	7.4	10130	2.1	12.1	15
2017	22	3.7	12.5	10122	2.8	0	27

2017	23	3.9	8.5	10139	4	0	26
2017	24	2.2	4	10146	4.3	7.4	27
2017	25	-1.8	2.2	10177	4.8	14	17
2017	26	-2.5	-0.9	10232	3.7	3.4	23
2017	27	-2.8	-0.8	10185	3.6	11.5	18
2017	28	-3.8	-1.3	10225	2.9	0.8	23
2017	29	-5.6	1.2	10248	1.6	0	32
2017	30	-5.4	2.8	10215	2.2	0	28

逐日气象数据由于数据量较大，容易出现数据缺失或数据乱码情况。本次实验中我们对缺失的气象数据进行插值处理，本实验采用的插值方法是多项式插值法^[39]。

WOFOST 模型输入的气象参数有日最高温度、日最低温度、平均气压、日平均风速、日总辐射、降雨量。逐日气象数据中不包含有日总辐射。日总辐射数据的获取可通过对逐日气象数据中的日照时长进行转换^[40]。

$$R_s = R_{\max} (a_s + b_s * \frac{n}{N}) \quad (3.2)$$

式中 R_s —— 太阳总辐射 (MJ/m^2)

R_{\max} —— 天文辐射 (MJ/m^2)

a_s 、 b_s —— 与大气状况相关的经验系数，分别取 0.25、0.5

n —— 日照时长 (h)

WOFOST 模型模拟参数输入：对气象数据进行格式整合（WOFOST 输入特定格式），导入数据。

3.2.3 基于 MODIS LAI 的 LAI 时序曲线提取

MODIS LAI 提取的 LAI 时序曲线用于 WOFOST 模型的同化阶段。

MODIS LAI 使用的数据源为 MODIS MCD15A3H，数据时段为 2014 年 10 月至 2020 年 5 月。实验区域为湖北省，湖北省在区块上分别位于 4 大区块，所

以本次 MODIS 数据选定区域为 H:27,V:5、H:27,V:6、H:28,V:5、H:28,V:6 共 2188 张 MODIS 图片影像。对 MODIS 数据进行辐射定标^[41]、大气校正^[42]、图像拼接^[43]等。

MODIS 数据的辐射定标：辐射定标是将记录的原始 DN 值转换为大气外层表面反射率。辐射定标可以消除传感器本身的误差，确定传感器输入口处的准确辐射值。

MODIS 数据的大气校正：MODIS 数据的大气校正可以减少大气和光照等因素对地物反射的影响，从而获得更为准确的地表反射率、辐射率、及其他物理模型参数。

MODIS 图像的拼接：本次研究的区域（湖北省）分别分布于地图板块的 4 块，为方便整理，本次实验对 MODIS 数据进行图片拼接，最终 2188 张 MODIS 影像在拼接后生成 547 张 MODIS 影像。

对 MODIS 影像进行 LAI：为保证提取区域与实验区域一致。MODIS LAI 的分辨率为 500m*500m，分辨率较低，为保证实验 MODIS LAI 时序曲线的提取的精准性，本次实验首先在 Google earth 影像进行精准定位，保证提取区域与实验区域一致。在影像确定后对其进行精准定位确定其油菜位置。本次实验提取点的设定范围为选定点附近的 3*3 个像素点的范围内。

MODIS LAI (MODIS MCD15A3H) 的影像时间间隔为四天一景^[44]，且其数据会由于气候等其他条件影响，MODIS LAI 数据会出现极端点或数据误差等情况。为获得较为精准的 LAI 时序曲线，本次使用 SAVITZKY-GOLAY 平滑滤波器对 MODIS LAI 提取数据进行平滑滤波处理^[45]。

3.2.4 实验区域油菜 LAI 实测数据

本研究采用的地面实测数据来源于武穴市华中农业大学作物试验研究基地（北纬 30°6'43"，东经 115°35'22"）。如图 3.1 所示该基地油菜小区分为 48 个大小大致相同地块，分别施以 8 种不同水平的氮肥（0、45、90、135、180、225、270 和 360 kg/ha）。数据的采集时间是从 2014 年 9 月到次年 5 月一个完整的油菜生长周期。



图 3.1 地面实验小区

3.3 WOFOST 模型的建立

WOFOST 具有极强的生物机理性，作为一个机理模型，它使用了多模块模拟。借用 CO₂ 的同化认同于作物生长的过程。作物的生长控制在物候阶段，物候阶段^[46]很好的解释了作物的发展过程以及发展过程中对环境变化带来的影响。

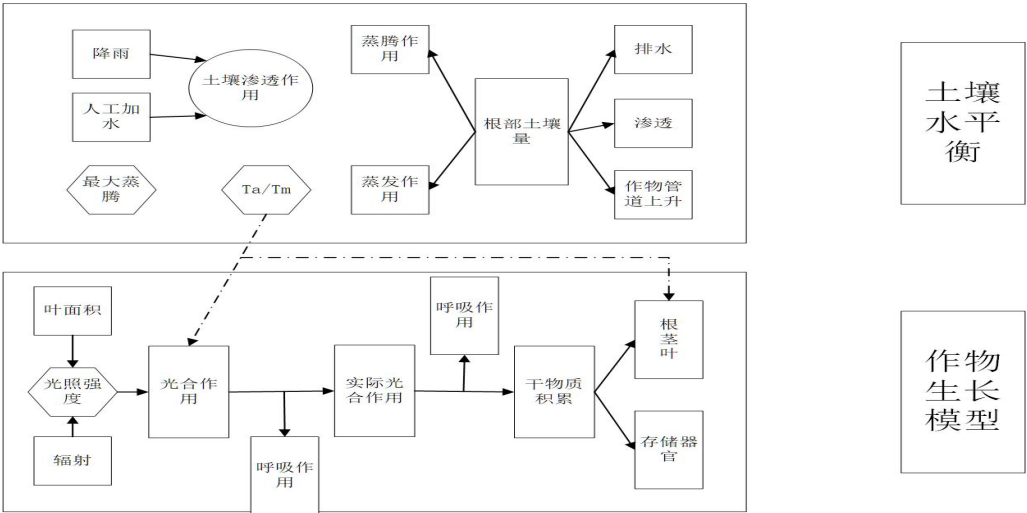


图 3.2 WOFOST 模型原理图

WOFOST 模型对 CO₂ 的同化作用分别有呼吸、蒸腾、作物发育、土壤的水平衡^[47]，模型原理如图 3.2 所示。

3.3.1 同化与呼吸作用

作物的每日同化效率是由作物每日吸收的太阳辐射以及叶面的光合作用演算计算获得。作物点光合作用以及光照强度的不固定性，使得同化效率的计算要考虑到叶面冠层的变化，叶面的树冠辐射有水平叶面方向和垂直叶面方向的两种辐射量^[48]。

垂直叶面的冠层辐射量可以由冠层最高处的辐射量以及关照的透光率计算获得。

水平叶面的冠层辐射量会随着太阳光照对作物的辐射角度而变化。该表达式表示在光照适宜的情况下（晴空）冠层顶端吸收的总辐射量^[49]。

$$I_0 = I * \sin(\beta) \quad (3.3)$$

关系式中， L （光照辐射吸收率）， $R_g(kg \cdot hm^{-2} \cdot d^{-1})$ （太阳辐射角度）

由于辐射的利用率并非百分百，冠层叶面积的增加会使得辐射利用率降低，其表达式为：

$$I_L = (1 - \rho) * I_0 * e^{-k * L} \quad (3.4)$$

关系式中， I_L （冠层叶面吸收有效辐射量）， L （叶面积指数）， k （消光系数）。

作物的呼吸，是作物生长的重要环节。作物的呼吸在真实温度和模拟温度下作物的不同器官的呼吸速率有这一个近似的表达式，如下：

$$R_{m,T} = R_{m,T_1} * Q^{\frac{T-T_1}{10}} \quad (3.5)$$

$$R_M = R_{m,T} * W \quad (3.6)$$

关系式中， Q 为呼吸商，定值为 2； T_1 为参考模拟温度，定值为 25℃； $R_{m,T}(kg \cdot hm^{-2} \cdot d^{-1})$ ， $R_{m,T_1}(kg \cdot hm^{-2} \cdot d^{-1})$ 为真实温度和模拟温度下作物的呼吸速率； $W(kg \cdot hm^{-2})$ 为作物干物质重量。

作物每日维持呼吸量 $R_M(kg \cdot hm^{-2} \cdot d^{-1})$ ：

$$R_M = R_{m,T} \bullet W \quad (3.7)$$

作物物质质量积累所消耗能量 $R_g(kg \cdot hm^{-2} \cdot d^{-1})$:

$$R_g = (1 - C_e) * (R_d - R_M) \quad (3.8)$$

$$R_d = (30/44) * A_d \quad (3.9)$$

关系式中, C_e 为转换系数, $R_d(kg \cdot hm^{-2} \cdot d^{-1})$, A_d 分别为甲醛、二氧化碳的同化速率。

3.3.2 作物生长过程与土壤水平衡

WOFOST 模型模拟作物生长过程中,作物的有效积温^[50]是模拟的重要依据。我们将作物的发育期拆分。作物的发育时期可拆分为两个阶段第一阶段(苗—花)和第二阶段(花—成熟)。作物的生长参数作为作物生长阶段的有效积温。作物的积温累积到一定程度时,作物进入发育时期。每日的最低温度和最高温度一定程度上决定了作物的当日有效积温^[51]。作物的有效积温依作物的特性而定,作物的发育速度近似的表达为每日积温和总积温的比值,表达式如下:

$$D_{r,t} = \frac{T_{ei}}{TSUM_j} (j=1,2) \quad (3.10)$$

表达式中, $D_{r,t}$ 表示在时间 t 时的发育速度(d^{-1}); $TSUM_j$ 表示阶段所需有效积温; T_{ei} 表示作物发育温度。

WOFOST 模型用 Development Stage 表示作物的生长发育, Development Stage 是状态变量。Development Stage 表达作物的生长时期。第一阶段用 Development Stage 为 0~1 表示,作物第二阶段用 Development Stage 为 1~2 表示。Development Stage 状态界限表示了作物的每日有效积温,当作物有效积温累计到一定程度时,作物进入新阶段。模型中 Development Stage 发育公式如下:

$$f = \frac{L - L_0}{L_0 - L_e} \quad (3.11)$$

$$DevelopmentStage = \frac{\sum_{i=1}^n T_e}{TSUM} * f \quad (3.12)$$

表达式中 L 、 L_o 、 L_e 表示为日照时长、最适应日照时长、最少日照时长； $TSUM$ 表示为有效积温。

WOFOST 模型中，作物的土壤的含水量平衡有 3 种状态。第一状态，土壤长时期温暖湿润状态，作物的生长需求水总量为作物的蒸腾作用和蒸发作用的总和。

第二状态，受限制条件下的土壤水平衡，在受限制条件下土壤的地下水位于较深地区，土壤水无法直接作用作物根部。土壤层以土壤深度可划分为两层，土壤的根部分为第一层，实际生根区域与最大根区之间为第二层。土壤划分有一个明显的梯度，土壤的梯度使得土壤中的水分也形成了一个水平衡梯度，梯度水平衡使得水存储和土壤中水的流失能够用蒸腾与挥发来进行计算。

第三状态，人工干预的土壤水平衡，在土壤水平受限制的情况下，可进行人工干预，通过人工浇灌水的方式让土壤中的水分达到水平横。

土壤水分的平衡有效性是由土壤的物理特性所决定的，作物的发育阶段（第一阶段）的水平衡是由人工灌溉水以及自然降雨、土壤层的蒸发作用以及土壤层的渗透作用维持的。

3.3.3 作物的干物质积累与分配

干物质积累形成是作物进行呼吸作用后，作物的各类器官产生的干物质进行再一次的分配^[52]。干物质的分配能够很好的了解作物的积累物质及作物所含有的营养物质。干物质分配公式为：

$$\nabla W = C * (R_d - R_{m,t}) \quad (3.13)$$

表达式中， $R_d(kg \cdot hm^{-2} \cdot d^{-1})$ 表示为每日甲醛同化速率； $R_{m,t}(kg \cdot hm^{-2} \cdot d^{-1})$ 为真实温度和模拟温度下作物的呼吸速率。作物的干物质分配中作物各类器官进行不同比例的分配。模型的干物质分配分为地上干物质 (∇W_{Above}) 和地下干物质 (∇W_{RT})；

$$\nabla W_{RT} = FR * \Delta W \quad (3.14)$$

$$\nabla W_{Above} = (1 - FR) * \Delta W \quad (3.15)$$

地上干物质 (∇W_{Above}) 会分配到作物的不同器官；

$$\Delta WLV = FL * (1 - FR) * \Delta Above \quad (3.16)$$

$$\Delta WSO = FO * (1 - FR) * \Delta Above \quad (3.17)$$

$$\Delta WST = FS * (1 - FR) * \Delta Above \quad (3.18)$$

表达式中, ΔWLV 为作物叶干物质分配; ΔWSO 为作物茎干物质分配; ΔWST 为作物果干物质分配, FL 、 FO 、 FS 为分配常数其和为 1。

3.3.4 LAI 叶面积模拟

模型中叶面积增长^[53]有两个阶段, 第一个阶段为作物的生长初期, 第二阶段为叶重的增加阶段。作物的生长初期叶面积增长会因温度而产生变化, 叶重增长以叶面积增长有着相关性。

模型中作物叶面一定程度上代表着叶片年龄, 叶片年龄计算如下, 作物叶片会被划分成多层, 用 $LV(i)$ 表示作物叶片点累计总重量。

$$LV(I) = \Delta WLV \quad (3.19)$$

$$LVAGE_i(I) = LVAGE_i(I-1) + \frac{T(I) - T_{BSE}}{35 - T_{BSE}} \quad (3.20)$$

表达式中, $LVAGE_i$ 为第 I 天叶片层为 i 的叶片年龄。 $T(I)$ 为第 I 天的日平均温度。 T_{BSE} 为作物衰弱的温度下界。

叶片衰老表达式如下; 叶片的衰老由多因素造成, 其中包括, 叶片我衰败, LAI 过高, 水胁迫等。

$$RELV_{N-P} = \sum_{i=1}^{i=N} LV(i) - (DSL V + DAL V) \quad (3.21)$$

表达式中 $DSL V, DAL V$ 为叶片衰败重量, $RELV_{N-P}$ 为去除衰败叶片重量。具体表达式如下;

$$LAI(I) = \sum_{i=1}^{i=N-P} LV(i) * SLA(i) \quad (3.22)$$

表达式中 $SLA(i)$ 为 i 层叶片的比叶面积。

3.4 WOFOST 模型与遥感数据同化

为了实现在大区域尺度获取准确有效的叶面积指数 LAI，本研究采用 WOFOST 模型与遥感数据同化的方式来弥补大区域尺度 LAI 数据量的不足。WOFOST 模型能够直接模拟作物的叶面积指数，在(wofost.wikispaces.com/FAQ)对模型的解释中，关于叶面积指数的计算是根据不同部位（叶、茎、果实）对叶面积指数的贡献进行累加计算的，这也非常符合油菜生长过程中不同生长期冠层不断变化的特征。此外作物模型参数众多且有些参数获取代价大、标定困难，而 WOFOST 模型是一种通用模型，通过定制不同的参数可以模拟不同种类的作物，具有很强的适用性，模型主要的参数在诸多文章中已经通过地面试验和遥感数据同化等方式在不同气象、土壤和管理条件下进行了比较充分的标定，能够通过设置默认值或取值范围一定程度上提高模拟的精度，针对本研究基本采用公开数据集的情况，只需要对模型的核心参数进行标定。

WOFOST 模型输入的气象参数有日最高温度、日最低温度、平均气压、日平均风速、日总辐射、降雨量。本次选取的气象站点数据有荆州、嘉鱼、麻城、天门、监利、钟祥、武穴 2014 至 2018 年数据。气象数据每日中所获取的数据中不包含有日总辐射。日总辐射数据的获得可通过对每日气象数据中的日照时长进行转换。MODIS LAI 数据来源于 <https://ladsweb.modaps.eosdis.nasa.gov/search/>，本实验使用的是 MODIS MCD15A3H 数据，其对应时间为油菜种植生长时期（10 月至下一年 5 月底）。使用的 MODIS 数据需要进行重投影^[54]。

使用 WOFOST 模型对水稻模拟的使用界面输入块包括 6 个模块，分别是 General、Crop、Weather、Timer、Soil、Reruns。

3.4.1 General 与 Crop 模块参数设定

General 模块 Number of successive production levels 选择 and simulation water-limited crop growth。

General 模块 WATER-LIMITED crop growth 选择 Effects of drought only。

General 模块 Summary seasonal soil water balance 选择 Whole system(1-D column)。

Crop 模块 Available crops 选择 Oilseed rape 1003, S-Spain

3.4.2 Weather 与 Time 模块参数设定

WOFOST 模型原有的气象数据有 Netherlands Wageningen(1972-2008)、Netherlands Swifterbant(1974-1989)、Netherlands Dekooy(1976-1985)、Philippines IRRI wet station site(1979-1991)。在我们将气象数据处理完成后将其保存到 WOFOST 模型的 WOFOST Control Centre\METEO\CABOWE 文件夹下。在将气象数据文件导入后在其 Weather 模块会产生相应的选择项,而后选择我们所需要选择的气象数据。

Timer 模块 General time 中的 Output interval in day 和 Start data water balance 设置为 1。

Timer 模块 Weather station 中的 start_year 选择模拟年份、Consecutive years 设置为 1。

Timer 模块 Crop timer 中 Start Day 选择为 fixed emergence data, Fixed Emergence 设置为油菜播种日期(冬油菜的播种日期大概在 10 月份)。Crop timer 中 END Day 选择为 Fixed end data, Fixed end data 设置为油菜的最终日期(油菜的收获时间大概在 5 月上旬到 5 月中旬)。

3.4.3 Soil 与 Reruns 模块参数设定

Soil 模块 Aailable soil types 选择为 EC-coarse

Soil 模块 Hydrology 中 Initial surface storage(cm)设置为 0.

Soil 模块 Hydrology 中 Macimum surface storage(cm)设置为 0.

Soil 模块 Hydrology 中的 Groundwater 选择的 initial available soil water(cm) 设置为 20

Maximum initial moisture content initial rooting depth(-)设置为 0.04

Soil 模块 Hydrology 中 Maximum rooting depth of soil(cm)设置为 120

Soil 模块 Hydrology 中 Non-infiltration 选择 Fixed

Soil 模块 Hydrology 中 maximum non-infiltrating 设置为 0

Reruns 模块是 WOFOST 模型同化的重要模块,在 Reruns 模块未选择的情

况下是对油菜进行给定参数的模拟，未能对其本地同化。

SPAN(Life span of leaves growing at 35-C (days)) 在 35° 下叶片生长时间、TSUM1(Thermal time from emergence to anthesis (-C.d))作物生长第一阶段有效积温、TSUM2(Thermal time from emergence to anthesis (-C.d))作物生长第二阶段有效积温、TDWI(Initial total crop dry weight (kg/ha))作物初始干物质重量、CVO(Conversion efficiency of assimilates into storage organ (kg/kg))同化转换为作物器官物质转换率、CVS(Conversion efficiency of assimilates into stem (kg/kg))同化转化为根茎的转化率、CEET(Correction factor for evapotranspiration in relation to the reference crop)作物蒸腾修正参数

Reruns 模块添加变量有：

表 3.2 Reruns 模块参数调整范围

参数	单位	最低值	最高值
SPAN	天	17	21
TSUM1	°C/天	150	240
TSUM2	°C/天	600	900
TDWI	Kg*hm ⁻²	40	90
CVO	Kg*Kg ⁻¹	0.6	0.85
CVS	Kg*Kg ⁻¹	0.66	0.7

在模拟水稻生长过程中为保证其品种以其对应，需要对上述参数进行调整，具体调整如表 3.2 所示；

通过对 Reruns 模块的参数设定使得模型模拟数据能够很好的拟合本地真实的油菜生长数据。

3.4.4 WOFOST 同化结果

对 LAI 进行提取前，先结合 Google earth 影像和 GF-1 影像确定所选地区是否为油菜种植区，并且该种植区位于气象站点附近，将此设为定位点。确定油菜范围后，将 MODIS LAI 数据按照时间顺序叠加，在各像元上生成对应的 LAI 时间序列曲线，为保证时序曲线的有效提取，设定范围一般是定位点附近的 3*3 个像素点。MODIS MCD15A3H 的影像时间间隔为 4 天，数据会由于气候等条件

出现极端点，为使其曲线更为平滑、准确，对提取的 LAI 曲线进行插值、平滑处理，本实验采用 SAVITZKY-GOLAY 平滑滤波器对时序曲线进行平滑处理。

最后得出的 LAI 时序曲线作为 WOFOST 模型调参的辅助数据。下为 LAI 插值平滑前后数据对比：

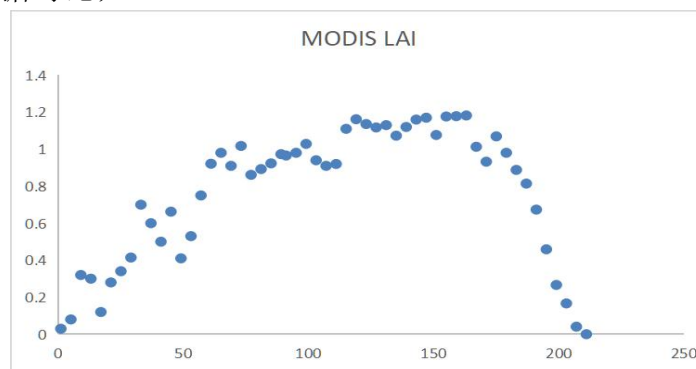


图 3.3 MODIS 提取 LAI

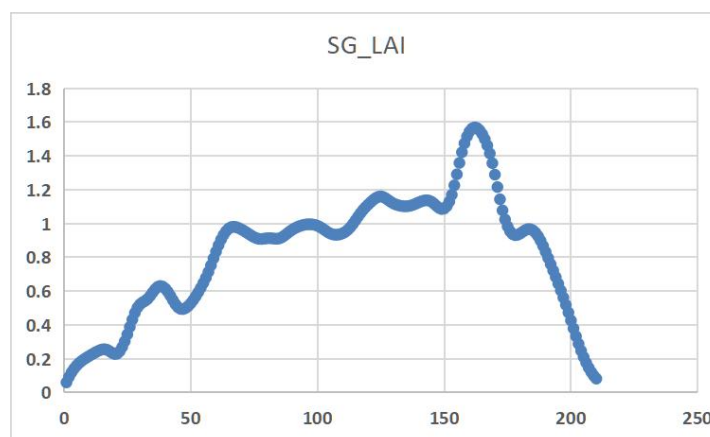


图 3.4 MODIS LAI 插值平滑

本实验采用查找表优化算法通过 LAI 将 WOFOST 模型与遥感数据同化，其 LAI 的优化函数定义为：

$$M = \sqrt{\sum_{i=1}^n \left(\frac{LAI_{si} - LAI_{re}}{LAI_{re}} \right)^2 / n} \quad (3.23)$$

其中为 LAI_{si} 和 LAI_{re} 分别表示模拟 LAI 和真实数据 LAI(MODIS-LAI)， n 表示生长的日期。 M 最小时真实 LAI 数据与模拟 LAI 数据的差异最小。我们利用已有实验田 LAI 数据以及 MODIS LAI 数据对 WOFOST 模型参数进行调参，实

现 WOFOST 模型的本地化, 将最终参数输入模型得到气象站点附近油菜的 LAI 生长曲线。图 3.5 显示了 2015 年荆州市站点 LAI 同化结果。




图 3.5 2015 年荆州市站点 LAI 同化结果

3.5 本章小结

本章主要是对 WOFOST 模型以及其模拟油菜的相关介绍。WOFOST 模型同化模拟油菜生长使用的数据有 MODIS -LAI 数据、气象日值数据, 以及部分实测油菜 LAI 数据。相关数据的来源以及处理方法本章都有对其进行详尽的介绍。本试验区域为湖北省的部分区域, 湖北省在 MODIS 数据模块划分在了 4 个不同模块中, 为保证后续对 MODIS LAI 的时序曲线提取, 实验对其进行了图像拼接, 四张 MODIS LAI 图像拼接为一块。针对气象数据实验对其进行了缺失值处理, 模型所需的部分数据需要对气象数据进行转换。最后对 WOFOST 模型的结构原理进行了详尽的介绍。

实验通过 WOFOST 模型与遥感数据同化的方式来获取大尺度的 LAI 数据。通过中间量 LAI 数据可以对油菜产量进行估测。本章的主要工作为: (1) 在数据采集和预处理的基础上构建 LAI 与产量的经验关系模型; (2) 利用 WOFOST 模型同化遥感信息, 获得准确的时间序列 LAI;

结合模拟数据已经油菜产量与 LAI 的建模可以对油菜进行大区域产量预测。

第 4 章 基于高分一号卫星数据的油菜产量估计

在通过第二章以及第三章的数据我们已经构建了油菜的产量模型，以及各地区模拟时序 LAI 数据。大区域油菜产量预测的实现必须通过遥感技术。大尺度区域产量估测需要对遥感图像进行图像到 LAI 的数据转化。LAI 时序数据与遥感数据进行建模，完成对遥感数据到 LAI 的过程的建模。

4.1 高分一号数据准备

本研究使用的遥感数据集由 24 张 GF-1 WFV 影像组成。其中，14 幅影像用于构建模型算法，并根据阳新县历年（2015 年-2020 年，2017 年影像云量过多无法使用）的 10 幅图像进行算法验证。表 4.1 列出了这些图像的信息摘要。油菜种植面积和产量统计年鉴数据从国家统计局和湖北省统计局下载。

表 4.1 用于模型构建的 GF-1 WFV 影像信息

覆盖区域	数量
荆州	4
麻城	2
种祥	2
武穴	2
嘉鱼	4

4.2 基于高分影像的大区域尺度 LAI 提取方法

以抽薹期和开花期的 LAI 作为中间量，使用 GF-1 WFV 数据再大区域尺度估算 LAI，从而对产量进行远程估测。其中用于建模的 LAI 值来源于 WOFOST 模型的同化结果。研究中所用的植被指数如表 4.3 所示，由 GF-1 多光谱波段构建。

表 4.2 植被指数 & LAI

植被指数	反演模型	决定因素 /R ²	阶段
NDVI	$y = -2.1076x^2 + 4.6991x + 1.4882$	0.7498	抽薹期
VARIGreen	$y = 3.6302x + 2.9215$	0.6917	抽薹期
MSAVI	$y = 2.8876x + 1.3787$	0.746	抽薹期
EVI	$y = -1.0104x^2 + 2.9926x + 1.4482$	0.7602	抽薹期
SR	$y = -0.2229x^2 + 1.7857x + 0.1191$	0.8209	抽薹期
NDVI	$y = 5.3612x^2 - 4.5728x + 4.3207$	0.1384	花期
VARIGreen	$y = -61.405x^2 + 19.333x + 2.7307$	0.7708	花期
MSAVI	$y = 14.342x^2 - 18.852x + 9.5592$	0.154	花期
EVI	$y = 0.7645x + 2.6508$	0.1282	花期
SR	$y = -0.0384x^2 + 0.5389x + 2.0373$	0.1508	花期

表 4.3 研究所用的植被指数

植被指数	公式
NDVI	$(\rho_{NIR} - \rho_{red}) / (\rho_{NIR} + \rho_{red}) \quad (4.1)$
VARIGreen	$(\rho_{green} - \rho_{red}) / (\rho_{green} + \rho_{red}) \quad (4.2)$
MSAVI	$[2R_{NIR} + 1 - \sqrt{(2R_{NIR} + 1)^2 - 8(R_{NIR} - R_{red})}] \quad (4.3)$
EVI2	$2.5 * (\rho_{NIR} - \rho_{red}) / (1 + \rho_{NIR} + 2.4 * \rho_{red})$

(4.4)

SR

 ρ_{NIR} / ρ_{red} (4.5)

从表 4.2 中可以发现 5 种表征植被绿度的植被指数在抽薹期与 LAI 均显著相关, R^2 均超过 0.69, 其中 NDVI、SR 与 LAI 具有非线性关系。结果显示 SR 指数与 LAI 的相关性最高, R^2 达到 0.82, 可作为抽薹期 LAI 的反演模型。在开花期, 只有 VARIGreen 与 LAI 显著相关, R^2 为 0.77, 其他指数均与 LAI 相关性不高。这是因为当油菜处于花期时, 冠层会出现明显的黄色花朵, 此时的冠层光谱是花和叶子的混合光谱, VARIGreen 此时可能是因为该指数突出了绿波段信息, 并且花的黄颜色更接近绿波段, 所以与 LAI 相关性更优。因此, 我们在花期选择 VARIGreen 进行 LAI 的反演。

结合 LAI 与油菜产量的关系式, 结合遥感数据就可以对区域油菜产量进行估计。




图 4.1 抽薹期的 NDVI 与 LAI




图 4.2 花期的 NDVI 与 LAI

实验数据表明油菜 LAI 与 NDVI 的建模相关性与油菜的生长阶段有着重要的关系，在油菜的抽薹期 LAI 与 NDVI 有着较强的相关性，相关系数达到了 0.7243，而油菜在花期时，NDVI 与 LAI 的相关性较低。




图 4.3 抽薹期的 VARIgreen 与 LAI




图 4.4 花期的 VARIgreen 与 LAI

在油菜 LAI 与 VARIgreen 建模的相关性分析中，我们可以看出 LAI 与 VARIgreen 在的相关性在油菜花期时是最强的。




图 4.5 抽薹期的 MSAVI 与 LAI




图 4.6 花期的 MSAVI 与 LAI

MSAVI 与 LAI 的相关性建模分析：在油菜抽薹期，MSAVI 与 LAI 的相关性最强。




图 4.7 抽薹期的 EVI2 与 LAI




图 4.8 花期的 EVI2 与 LAI

对比 NDVI、MSAVI、VARIGreen, EVI2 与 LAI 的相关性建模较差, 在油菜的不同时期, 建模都不是很理想。




图 4.9 抽薹期的 SR 与 LAI




图 4.10 花期的 SR 与 LAI

通过各植被指数与 LAI 的相关性建模分析的出：油菜抽薹期 LAI 与 SR 指

数的相关性最强，油菜花期 LAI 与 VARIgreen 指数的相关性最强。

于是，我们得到基于高分 1 号宽画幅的地面 LAI 估算模型如下：

$$LAI_{\text{Bolting Stage}} = -0.2229 * SR^2 + 1.7857 * SR + 0.1191 \quad (4.6)$$

$$LAI_{\text{Flowering Stage}} = -61.405 * VARI_{\text{greeng}}^2 + 19.333 * VARI_{\text{green}} + 2.7307 \quad (4.7)$$

4.3 基于高分一号影像的作物产量估算模型

最终我们可以通过以下步骤进行快速的油菜产量估测：（1）下载 GF-1 WFV 数据（云量较少、包含油菜的抽薹期和花期数据），进行数据预处理；（2）在油菜花期影像中利用金字塔残差网络提取油菜的类别；（3）通过 LAI 估算模型公式计算抽薹期和花期各像素油菜 LAI 值，再通过估产算法公式计算产量值；（4）根据 GF-1 影像中县域范围内油菜的种植区域、单位像素的面积、单位面积的产量得到该地区当年的油菜总产量。

通过对 LAI——产量的建模以及高分影像到 LAI 的建模整理得以下估产模型：

$$Yield = 581.82 \times \left(-0.2229 * SR^2 + 1.7857 * SR + 0.1191 \right)_{\text{BoltingStage}} + 91.47 \times \left(-61.405 * VARI_{\text{green}}^2 + 19.333 * VARI_{\text{green}} + 2.7307 \right)_{\text{FloweringStage}} - 63.10 \quad (4.8)$$

LAI Bolting Stage 为抽薹期油菜 LAI 值，SR 为抽薹期 GF-1 影像 SR 植被指数，LAI Flowering Stage 为花期油菜 LAI 值，VARIgreen 为花期 GF-1 影像 VARIgreen 植被指数，Yield 为最终油菜产量。

4.4 本章小结

油菜的大区域产量估测的实现是通过对遥感数据的分析处理，建立对遥感数据模型。已知研究表明作物 LAI 与作物产量有着密切的联系，产量估测实现的取决于 LAI 的已知情况。实现大区域产量估测就需要对遥感数据进行建模，通过模型将遥感数据转换为 LAI 指数，本章通过对 WOFOST 模型结果 LAI 与高分一号数据进行转换建模，实现从遥感数据到 LAI 指数。通过结合产量模型与遥感转换 LAI 模型双模型得出最终的基于遥感数据预测油菜产量模型。

第5章 基于湖北省的油菜产量估测方法验证

本实验研究区域为湖北省的各市区，为对算法进行验证。作物的产量与实验产地有着重要的关系，不同地区的同种作物产量也会有这不同，作物产量与作物种植土壤，物候环境有着密切关系，为保证实验一致性，本实验对湖北省的阳新县、武穴市进行产量预测。最后将阳新县、武穴市的产量预测数据与湖北省年鉴数据进行比对。

油菜产量估测的整体实验流程如下：

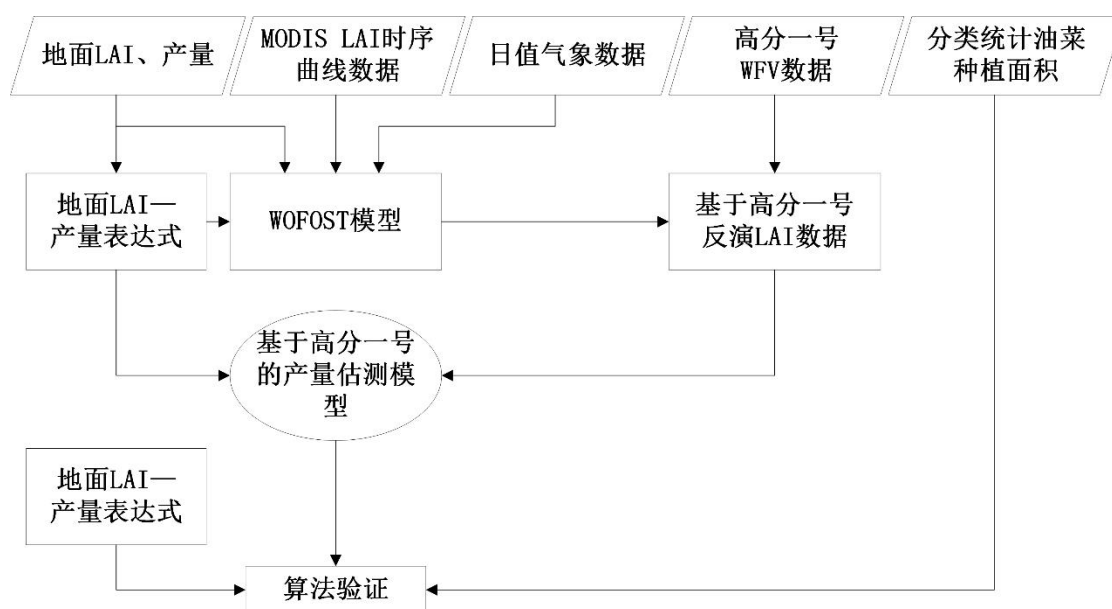


图 5.1 产量估测流程图

5.1 用于模型验证的数据准备

下表为阳新县验证实验数据列表：

表 5.1 用于模型验证的阳新县 GF-1 WFV 影像信息

获取时间	油菜期
2015.1.22	抽薹期
2015.3.12	花期
2016.2.3	抽薹期
2016.3.19	花期
2018.2.6	抽薹期
2018.3.28	花期
2019.1.17	抽薹期
2019.4.1	花期
2020.1.29	抽薹期
2020.3.18	花期

5.2 基于深层卷积神经网络的地物提取

多光谱遥感图像的采集是通过对地物的空间和光谱信息构成的，其涉及的应用领域包括农业、环境监测、城市建设等^[55]。多光谱地物分类技术^[56]也是遥感技术的一个重要技术。在近年来，总多的研究人员提出了大量的基于多光谱的地物分类方法。

多光谱分类^[57]的方法分为 2 种方法，一种为监督式的分类，一种是非监督式的分类。非监督式的分类方法是对分类数据不使用标签数据作分类，而是通过模型的自我学习后自主的对地物进行分类，因此这类方法适用于先验知识匮乏的简单的地物分类。监督式的分类方法是对分类数据以及标签数据进行分类，这类分类方法对比非监督式的分类方法有这较高的精准度。本试验中对油菜产量估测的方法中，需要对广域的油菜种植面积进行统计，适合用监督式的分类方法对其进行分类。

监督式的高光谱分类的方法有多种。通过构建支持向量机（SVM）对多光谱高分图像进行不同的分类标记来对图像面来进行分类^[58]；基于多光谱高分图像特征信息的决策树分类^[59]；随机森林算法对多光谱高分图像的分类^[60]；基于

多光谱遥感图像的最大似然估计算法对图像进行分类^[61]；基于多光谱图像的自适应最小距离调整算法分类^[62]。以上的基于多光谱图像的分类方法是较为经典的算法，但都较为浅层，分类精度不算高。

随着深度学习的不断革新，深层次的神经网络在机器学习领域中发挥着不可替代的作用。深层次的神经网络在图像处理、计算机视觉、信号处理等方面有着极其强大的能力。Alex Net 架构^[63]是 Krizhevsky 在 2012 年首次提出的卷积神经网络架构。Alex Net 对图像的分类有着极其强大的分类作用，这预示着卷积神经网络也具备这强大的分类能力。

在分类精准度不高的情况下，为提升分类精准度，对卷积神经网络的卷积层进行提升。但更深层次的卷积网络有着众多的问题，梯度爆炸、梯度消失以及网络无法收敛的问题等。网络的复杂化并非等同于分类精度的提升，反而会弄巧成拙导致分类精度的降低。残差网络针对卷积神经网络的这些问题做出了应对，残差网络提出了残差网络学习与恒等连接方式。这两种新方法的提出让网络架构可以得到改变，在使用恒等连接方式对网络的改进不会增加网络参数，并且不会使得计算变得更为复杂，增加恒等方式的卷积神经网络对比传统卷积神经网络性能更好。

光谱-空间残差网络^[64]是基于残差网络提出的新型网络，其使用了光谱与空间残差单元对图像中的光谱特征和空间特征连续的提取，在双残差块的特征提取作用下，深度学习模型中出现准确度下降的问题能得到缓解。为将模型泛化应用到多光谱遥感数据上，Paoletti 对模型进行了进一步的改进，在光谱-空间残差网络的基础上改进提出了金字塔残差网络^[65]。金字塔残差网络将卷积层的金字塔残差块进行分组，划分出金字塔残差块，且在卷积层的特征维数上进行累加，在金字塔残差网络中对高光谱遥感图像的空间特征以及光谱信息的多样性进行提取，使得对高光谱遥感数据的分类变得更为精准。

金字塔残差网络在图像分类的问题上有着显著的效果，金字塔残差网络的针对数据为高光谱遥感数据，对于在多光谱遥感数据上的分类问题上，金字塔残差网络的分类还达不到其理想效果。本实验使用了一种基于金字塔残差网络的新算法对多光谱数据进行分类，金字塔瓶颈残差网络。金字塔瓶颈残差网络对卷积核的大小以及网络层进行改进，改进后的网络能够对多光谱图像数据中的光谱与空间信息进行特征提取，从而实现对多光谱图像数据的分类。金字塔

瓶颈残差网络通过对特征映射维度的增加，以及在残差块单元上增加多光谱图像的光谱通道数，残差单元的深度在递进后对多光谱图像数据的特征提取就越多。金字塔瓶颈残差网络中还引进了新的网络层，归一化层 Batch Normalization（BN 层），在引进归一层后网络的泛化能力得到了很大的提升，较少了网络过拟合的问题发生。

5.3 基于金字塔瓶颈残差网络的高分一号数据分类

5.3.1 金字塔残差网络

金字塔瓶颈残差网络的结构有这与传统的残差网络不同的结构，金字塔瓶颈残差块的卷积层使用的是相同的一个拓扑结构。网络卷积层中的输入与输出层的特征通道先缩小再缩回来，此结构能够让模型运行效率更高。改进后的网络在对多光谱遥感图像分类性能上优于其它的网络。如图 5.3 所示的残差单元结构为空竹式结构，输入式结构的通道数大于中间层，小于输出层。为保证其输入与输出一致，需要对其进行映射恒等变换，残差单元对其进行一个零填充的连接。此残差单元对自然图像的处理只能对空间特征提取。




图 5.2 卷积 a




图 5.3 卷积 b




图 5.4 卷积 c

Paoletti 引入的金字塔残差网络对高光谱图像数据的分类。在金字塔残差网络结构中，残差块输出的特征图是逐级增加的，呈现出来的结构类似于金字塔，自顶向下逐渐变宽。模型由 5 个模块构成共同构成一个深层的神经网络。网络模块有：输入层、残差金字塔模块（P1、P2、P3）、池化层、全连接层。残差金字塔模块的组成是由三个金字塔瓶颈单元构成，残差模块如图 5.4 所示。金字塔模块 P3 在输出时进入池化层对输出数据进行一个下采样，下采样后再对其进行整理传输进网络模型最后一层进行分类。金字塔瓶颈残差网络的输入为多光谱图像，输出为图像的分类图。

5.3.2 基于多光谱高分图像数据的金字塔残差网络

金字塔残差网络的提出是为了对高光谱图像数据进行分类。高光谱与多光谱的分辨率有这一定差距，金字塔残差网络对多光谱图像的分类效果无法达到与高光谱的分类效果。为使得金字塔残差网络能够泛化到多光谱图像的分类上，本实验对金字塔残差网络进行结构上的修改。

多光谱图像与高光谱图像的分辨率有着不同，多光谱图像的空间分辨率对比高光谱图像略高。图像分辨率的高低决定着图像空间信息的多少，高分辨率图像内包含的空间结构以及纹理特征都更为清晰。结合金字塔残差网络可以得出高光谱图像数据的分类中空间信息发挥的作用有限。多光谱图像对比高光谱图像有着更为丰富的空间结构信息。基于高光谱与多光谱数据的不同，在试验模型中增加了对图像块大小的输入，以此来多多光谱图像空间结构以及纹理特征进行更为细致的提取分类。对于多光谱图像数据的输入，我们对输入图像的大小设定为 27×27 ， 27×27 的大小的图像特征提取能够提取较大的空间纹理信息。在图像输入大小上可以有其他的选择，在输入更大的图像时，需要有更多的训练数据来进行训练。多光谱的纹理细节对比高光谱更为丰富，在减小卷积核大

小的情况下，能够使得卷积核的截至频率变大，在较小的空间范围内捕获到图像的更多特征。

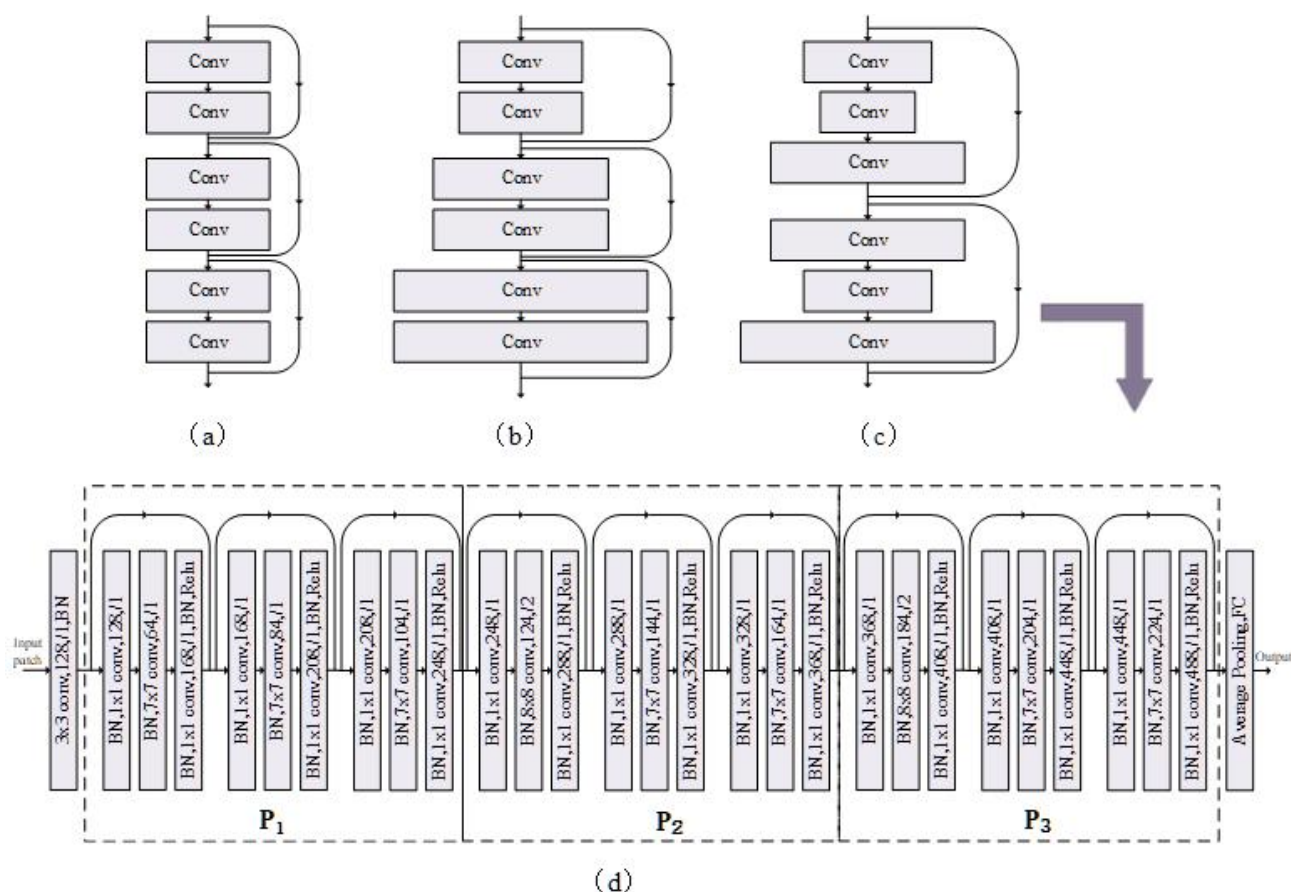


图 5.5 金字塔残差网络结构图

多光谱图像与高光谱图像的另外一区别在于波段数量的多少，高光谱图像的波段数量远远多于多光谱图像。图像的波段数与卷积核之间有这密切的相互性。波段数量的大小影响着卷积核数量的多少，在试验中卷积核的减小同比是卷积核数量的增加，在数据由高光谱转为多光谱图像的情况下，模型中的卷积核数量也由之前的 103 减至 64。

金字塔残差网络结构的详细设计如图 5.5 所示，其中 *conv*, *BN*, *Relu* 分别代表的是卷积层、池化层、以 *relu* 函数的激活层，网络结构的最后是 *soft max* 对图像进行输出。模型的结构图所示：

对模型数据的输入处理，为减少数据钢量对结果的影响，试验将多光谱图像归一化处理；为保证图像输入的方块大小，多光谱图像需要对边界填充。

5.4 基于多光谱图像分类结果分析

本次分类试验采用的数据是湖北省阳新县的高分一号数据，图像的获取时间分别是 2014~2020 年油菜花期，即每年的 3 月。油菜在 3 月份花期时，油菜花呈现黄色，在高分一号数据上有着显著的呈现，因此可以对其分类可以获得一个较为精准油菜种植分类。

油菜分类面积与湖北省年鉴统计数据比对分析结果如下：

表 5.2 分类结果分析表

年份	年鉴数据	分类数据	误差率
2015	16.82	17.36	3.2
2016	16.44	15.67	4.7
2018	15	15.48	3.2
2019	17.66	18.16	3.2
2020	18.3	17.66	3.4

由于 2017 年的高分一号数据云量过多，分类效果没有保证，在此并未对其进行分类。

图像的分类结果如下所示；

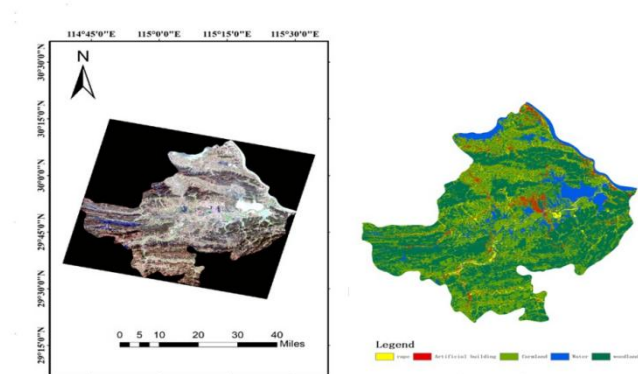


图 5.6 阳新县分类结果图

5.5 算法验证

通过基于金字塔瓶颈残差的优化网络提取油菜的种植面积，我们可以实现在县、市域尺度的油菜估产。为了验证算法的有效性，我们选择地面实验区的临近县市，湖北省黄石市阳新县、武穴市对模型的有效性、鲁棒性进行验证。采用2014年——2020年阳新县及武穴市油菜抽薹期和花期的GF-1 WFV数据进行县域尺度的油菜估产，并与统计年鉴数据进行对比，结果如表5.3、5.4和图5.7、图5.8所示。由于验证数据2015、2016年影像部分区域存在少量薄云，造成了光谱数据的混淆，不但影响了油菜提取的精度，也使得估产算法中所用的植被指数存在误差，影响了最终的估产结果。总体而言，该算法估算误差低于6%，能够有效地实现县域大尺度的油菜产量估测。

表5.3 阳新县油菜产量估测结果与统计年鉴对比

年份	图鉴面积 /(千公顷)	分类面积 /(千公顷)	图鉴产量 /(吨)	预测产 /(吨)	误差率 /(%)
2015	16.82	17.36	32393	34142.53	5.4
2016	16.44	15.67	33372	31420.02	-5.8
2018	15	15.48	35397	36037.11	1.7
2019	17.66	18.16	37086	36064.74	2.7
2020	18.3	17.67	39622	41210.17	4.0

表5.4 武穴市油菜产量估测结果与统计年鉴对比

年份	图鉴面积 /(千公顷)	分类面积 /(千公顷)	图鉴产量 /(吨)	预测产量 /(吨)	误差率 /(%)
2014	30	31.6	77318	75115	2.85
2015	28.96	28.22	73574	74674	1.5
2017	27.13	27.81	67852	71460	5.32
2018	18.74	18.21	45531	44499	2.23
2019	21.23	20.08	5139.	49770	3.14

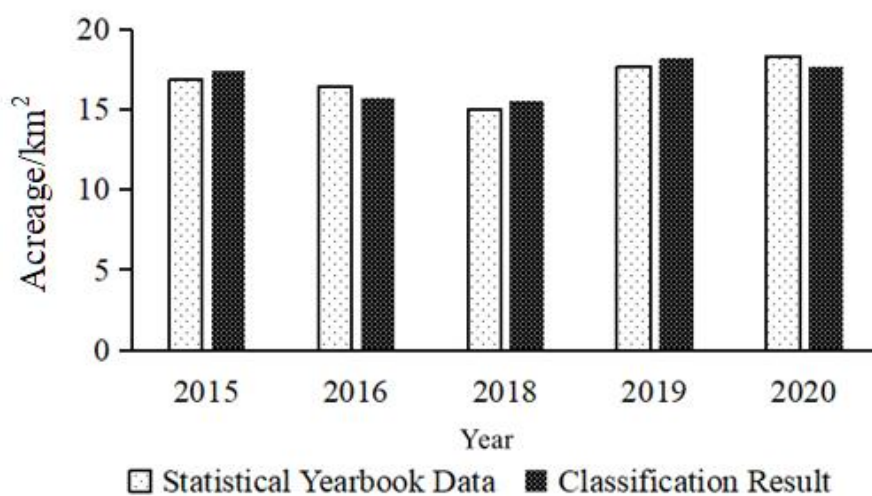


图 5.7 油菜提取结果与统计年鉴对比

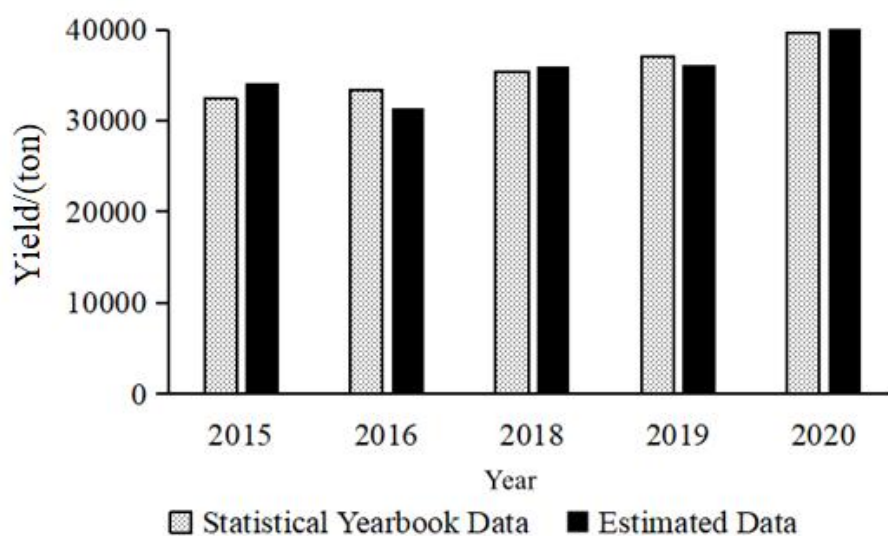


图 5.8 油菜估产结果与统计年鉴对比

卫星数据不足可能是一种不利条件。在我们的方法中，使用了油菜种子抽薹期和花期的卫星图像。花期大约在3月中旬，抽薹期在1月底和2月初。中国的主要种植区域是中部和南部地区，2月份可能会持续降雨三周以上。因此，建议使用高时间分辨率的卫星数据进行产量估算。相比之下，由于16天的重访期，陆地卫星8号的图像不是好的选择。该模型的使用受到气候因素的限制。在这个实验中，估计了两个城市的油菜产量。然而，油菜的适宜种植区域跨越了整个中国，物候差异也不一致。例如，一些地区的开花期可能会因天气较冷

和种植较晚而推迟，因此无法从3月份的高分1号图像中准确提取种植范围和蔬菜指数，从而导致总体产量估计不准确。因此，在重现工作之前，有必要考虑当地气候因素是否与我们的研究区域相同，或者根据当地气候来调整数据收集的时间。

5.6 结论分析

在这项研究中，我们开发了一种新的算法来估计大面积的油菜产量。该方法以遥感图像为输入，描述了叶面积指数与油菜产量之间的回归关系。在进行数据分析的同时，进行了大量的地面试验。利用局域 WOFOST 模型得到时间序列地面 LAI，提取油菜关键生长期的 LAI。利用覆盖油菜抽薹期和花期的高分1号 WFV 数据，估算了大面积的油菜产量。通过实验得出了一些结论。（1）抽薹期和开花期的叶面积指数组合可以实现准确的产量预测。（2）简单比率指数与抽薹期叶面积指数的相关性最大。（3）在开花期，VARIGreen 与叶面积指数高度相关。在湖北省武穴市验证了产量估算算法的有效性，结果表明，与统计年鉴中的数字相比，2014-2020 年的产量估算误差小于 6%。这说明了我们的方法在大区域范围内准确预测油菜产量的可行性。

5.7 本章小结

本章对油菜产量估测的方法进行了介绍以及对湖北阳新县及武穴市的油菜产量进行了实验预测。预测结果与实际年鉴数据的比对结果表明了本实验算法的可行性与准确性。最后的预测结果与年鉴数据误差在 6%以内。

第 6 章 LSTM 对油菜 LAI 生长时序曲线的预测

当前算法的产量预测是通过现有数据对作物进行产量预测。通过对过往的产量预测可知，LAI 与产量的关系密切。LAI 时序曲线的预测能够对产量的预测有一个更好的前瞻性。并且针对的预测可以对作物生长策略进行调整，一定程度上能对产量增加有一个推动作用。

长短期记忆人工神经网络^[66]（LSTM），是一种依据时间的循环神经网络（RNN），能够很好的学习到训练事务的长时期的规律。




图 6.1 循环神经网络层




图 6.2 长短期记忆神经网络

LSTM 能够很好的避免事务的长期依赖问题^[67]。LSTM 能够长时间的记录实验事务实践中的默认动作。

递归神经网络^[68]的形式是神经网络的重复模块链。在 RNN 中重复模块链是由简单的结构而构成的。LSTM 的重复链也是类似的链的结构，但重复链模块的结构与 RNN 又有这不同如图（6.1、6.2）。LSTM 模型在链式中加入了更多的

结构，如图（6.3）所示，在模型中除了输入门、输出门外还新加入一个遗忘门。通过遗忘门对数据进行筛选，丢弃部分数据。




图 6.3 LSTM 单元结构

6.1 长短记忆神经网络（LSTM）与循环神经网络（RNN）

6.1.1 循环神经网络

在处理序列数据模型中，循环神经网络^[69]（RNN）对比其他模型有着较大的优势。RNN 在自然图像以及自然语言处理领域中取得了不错的成就，在循环神经网络应用领域的不断拓展下，RNN 被运用于时间序列数据的预测^[70]。RNN 的基本结构包含有输入层、隐藏层、输出层。数据的传输与信息的交互会在不同层之间进行；归属于同一层的数据信息是无法进行传输与交互的，因为在同一层的不同神经元之间没有链接通道。网络的每一层都是结构都是独立的，因此网络各层的参数集也不同，各层的参数集是相互独立的。传统的 RNN 是无法对序列数据进行处理的。为了能够让 RNN 具备对序列数据的处理，需要在 RNN 的中间层中构建数据传输与信号交互通道，即是，神经元之间的传输通道。RNN 的隐藏层在改进后网络能够很好的对序列数据进行处理。RNN 隐藏层工作原理如图 6.4 所示：

图中， x 输入， h 为隐藏层的状态信息， o 为 RNN 中对输入序列做出的响应，

L 为目标与响应之间的偏差。 U, V 为 RNN 中各层的连接权重矩阵, W 为层之间的神经元之间连接参数矩阵。在 RNN 中 U, V, W 在不同时刻的参数矩阵是各自相同的, 这使得 RNN 能够很好对时间序列数据进行处理。

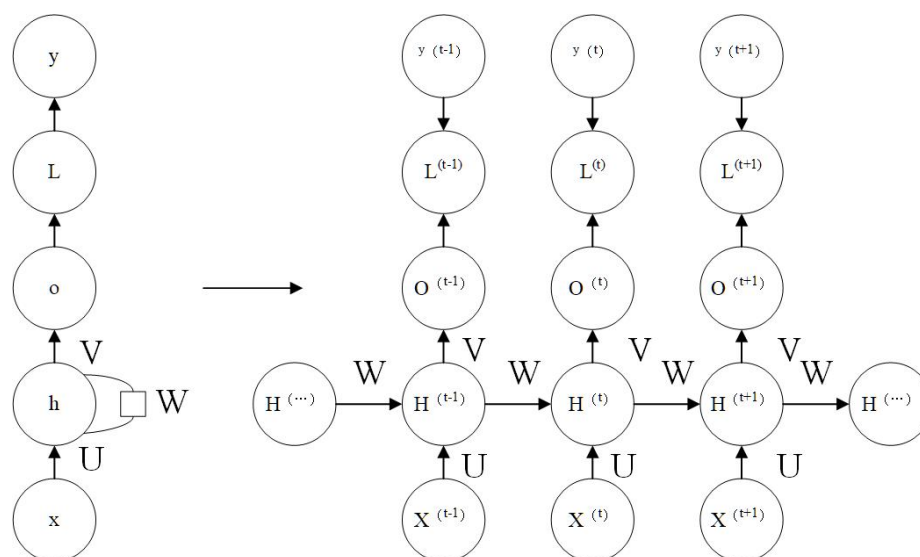


图 6.4 RNN 隐藏层原理图

RNN 中输入, 状态信息预计输出之间的关系可以用以下关系式表达:

$$h_t = f(U * x_t + W * h_{t-1} + b) \quad (6.1)$$

$$O_t = g(V * h_t + c) \quad (6.2)$$

6.1.2 长期依赖问题

RNN 在运用到现实中有这些困难, 较为严重的困难是 RNN 中的长期依赖问题。RNN 在对时序数据处理时, 会结合过往的时序数据与现今的数据进行有效分析, 对时序数据进行综合分析从而获得并输出未来某时刻的数据, 即预测值。时序数据的当前信息依赖于过往某时刻的状态信息, 当时间序列跨度比较短时, 这短时期的依赖关系为短期依赖情况, RNN 对短期依赖情况能够很好的处理; 当时间序列跨度比较长时, 这种长时期的依赖关系为长期依赖的情况, 在依赖关系种, 长期依赖关系种 RNN 难以构造时序模型。

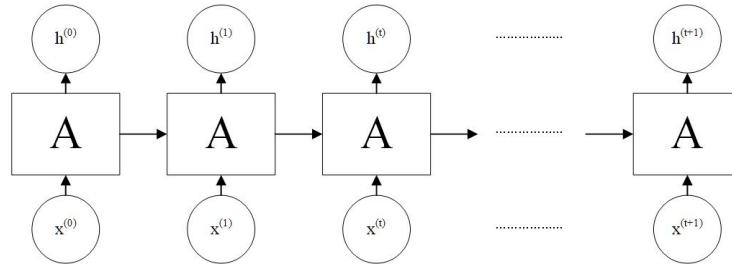


图 6.5 长期依赖

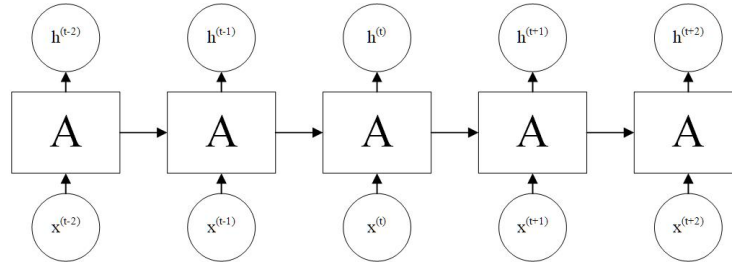


图 6.6 短期依赖

RNN 在应用过程中会有梯度消失^[71]与梯度爆炸的问题产生。RNN 在处理时序数据时,运用反向传播算法对模型中的参数矩阵进行更新,参数矩阵 U, V, W 核心算法是传统的梯度下降^[72], 损失函数 L 中对 U, V, W 在 t 时刻的偏导关系如下所示:

$$\frac{\partial L^{(t)}}{\partial V} = \frac{\partial L^{(t)}}{\partial o^{(t)}} \cdot \frac{\partial o^{(t)}}{\partial V} \quad (6.3)$$

$$\frac{\partial L^{(t)}}{\partial W} = \sum_{k=1}^t \frac{\partial L^{(t)}}{\partial o^{(t)}} \frac{\partial o^{(t)}}{\partial h^{(t)}} \left(\prod_{j=k+1}^t \frac{\partial h^{(j)}}{\partial h^{(j-1)}} \right) \frac{\partial h^{(k)}}{\partial W} \quad (6.4)$$

$$\frac{\partial L^{(t)}}{\partial U} = \sum_{k=1}^t \frac{\partial L^{(t)}}{\partial o^{(t)}} \frac{\partial o^{(t)}}{\partial h^{(t)}} \left(\prod_{j=k+1}^t \frac{\partial h^{(j)}}{\partial h^{(j-1)}} \right) \frac{\partial h^{(k)}}{\partial U} \quad (6.5)$$

$$\frac{\partial L^{(t)}}{\partial U} = \sum_{k=1}^t \frac{\partial L^{(t)}}{\partial o^{(t)}} \frac{\partial o^{(t)}}{\partial h^{(t)}} \left(\prod_{j=k+1}^t \frac{\partial h^{(j)}}{\partial h^{(j-1)}} \right) \frac{\partial h^{(k)}}{\partial U} \quad (6.6)$$

$$\prod_{j=k+1}^t \frac{\partial h^{(j)}}{\partial h^{(j-1)}} = \prod_{j=k+1}^t f' \cdot W \quad (6.7)$$

在 RNN 在实际应用中, 激活函数为 \tanh , \tanh 激活函数的求导范围为 $[0,1]$, 在参数矩阵中 W 的特征值在不大于 1 的情况下, 在特征运算过程中会使得其偏导数变得非常小, 会导致出现梯度消失问题; 参数矩阵中 W 的特征值在大于 1 的情况下, 在特征运算过程中会使得其偏导数变得非常大, 会导致出现梯度爆炸问题。RNN 的梯度消失与梯度爆炸问题的出现极大程度上制约了 RNN 在序列数据上的运用, 使得 RNN 无法实现时序数据的预测。

6.1.3 长短期记忆神经网络 (LSTM)

长短期记忆神经网络能够很好的解决 RNN 中存在的长期依赖问题, 长短期记忆神经网络被提出的意义也在于此。长短期记忆神经网络针对 RNN 存在的问题进行改进的与 RNN 相比长短记忆神经网络避免了传统 RNN 出现的梯度消失与梯度爆炸问题, 并且能够对序列数据进行长期依赖关系的预测建模。长短期记忆神经网络与 RNN 对比下, 长短期记忆神经网络比 RNN 多加了一个状态变量 C , 用状态变量 C 对时序的状态进行保存。如下为长短记忆神经网络与 RNN 的对比图:




图 6.7 RNN 与 LSTM 结构对比图

长短期记忆神经网络对于时序数据的处理预测方面有着极其强大的处理能力, 因此长短期记忆神经网络被广泛应用于时序数据的处理。长短期记忆神经

网络对比 RNN，长短期神经网络在模型训练中，能够对过去某时刻的时序数据进行更新与删除。长短期记忆神经网络中的数学表达式如下：

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_f] + b_f) \quad (6.8)$$

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_f] + b_f) \quad (6.9)$$

$$i_f = \sigma(W_i \cdot [h_{f-1}, x_i] + b_i) \quad (6.10)$$

$$O_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (6.11)$$

$$C_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (6.12)$$

$$C_f = f_f * C_{t-1} + i_f * C_f \quad (6.13)$$

$$h_t = o_t * \tanh(C_t) \quad (6.14)$$

长短期记忆神经网络是基于 RNN 网络的基础上进行改进的新模型，长短期记忆神经网络在 RNN 的模型基础上引入了新的状态单元以及门控结构。 C_f 为长短期记忆神经网络单元 f 时刻的状态单元； C_f 为状态更新参数，即下一阶段的长短期

记忆神经单元的下阶段状态； h_t 为长短期记忆神经网络在 t 时的隐藏状态信息； f_t, i_t 和 o_t 是长短期记忆神经网络的遗忘门、输入门、输出门在时刻 t 的相关参数，即激活向量。 W_c, W_f, W_i, W_o 是长短期记忆神经网络的相应权值矩阵； b_c, b_f, b_i, b_o 是长短期记忆神经网络中相应权值的偏值； σ 以及 \tanh 为长短期记忆神经网络的非线性激活函数。

长短期记忆神经网络相比 RNN 它引入了状态存储单元 C_t 来记录和传递时间序列数据，长短期记忆神经网络对遗忘门、输入门、输出门的控制是通过 *sigmoid* 激活函数输出的 $[0, 1]$ 实现控制的。 f_t, i_t 和 o_t 相关激活向量是遗忘门、输入门、输出门是，隐藏状态信息 h_{t-1} 在 t 时刻输入 x_t 与函数 σ 作用下获得的，遗忘门 f_t 是长短期记忆神经网络中决定某些历史状态该将被删除的单元；输入门 i_t 是长短期记忆神经网络中选定参数信息输入到网络中的单元；输出门 o_t 是长短期记忆神经网络中决定下一阶段状态参数的输入的单元，控制着哪些输出会进入下一个长短期记忆神经网络单元的单元。

长短期记忆神经网络通过对状态单元以及门控单元实现对序列数据的建模。

6.2 叶面积指数 (LAI) 的预测

作物的叶面积指数 (LAI) 是作物生长状态以及产量的一种侧面表现, 作物 LAI 的预测对于作物产量预测以及作物生长状态调整都有着其重要作用。

对油菜 LAI 进行短期的预测无法完全对油菜作物的生长状态做出反映, 但对油菜 LAI 进行长时间的预测, 预测结果会因为时间跨度过大以及输入信息的不足而造成精准度不够的问题。为了对模型模拟的时间长度, 实验对其进行多次实验, 通过多次实验的分析得出, 对油菜的 LAI 预测时间跨度设为 20 天, 通过对过往 LAI 的数据记录为往后的 20 天油菜 LAI 数据进行预测, 对油菜的生长状态进行一个预先估测。

气象条件作为作物生长的重要因素之一^[73], 对油菜的生长有着重要影响。为保证模型模拟预测的准确性, 在模型的特征参数中, 我们将气象数据作为特征参数输入进模型中, 为保证特征数据的一致性, 将数据进行归一化处理, 特征数据被缩放至[0, 1]之间。

使用长短记忆神经网络对油菜的 LAI 进行预测, 长短记忆神经网络建立的模型结构是多层长短记忆神经网络结构。长短记忆神经网络的网络层数为 3 层, 单层的隐藏神经元为 38 个, 步长设置为 N 天的数据。模型的输入为时间于 LAI 的二元组数据 (LAI, Time), 模型的输出为 N~N+20 的油菜 LAI。

在模型计算到 N 时, 通过三层长短记忆神经网络结构的输出为 h_N , 在输出之后 h_N 通过一个全连接层便得到了油菜的 20 天预测 LAI, 即 y' , 以下为连接表达式:

$$y' = W_y h_N + b_y \quad (6.15)$$

表达式中, y' 为预测结果; W_y 为长短记忆神经网络的权重矩阵, b_y 为模型的偏置向量。

长短记忆神经网络模型的训练过程中, 使用的优化算法为 Adam^[74], 损失函数为 MM

$$MM = \sum_{t=N+1}^{N+15} (LAI'_t - LAI_t)^2 \quad (6.16)$$

其中的 (LAI'_t, LAI_t) 分别为: 在时刻 t 时油菜的预测 LAI、标记油菜 LAI。

6.3 长短期记忆神经网络的参数调优

在长短期记忆神经网络对油菜预测的模型中，为了能使得预测效果具有更好的性能，实验将模型的超参数以及权重赋值初始化进行多次实验，求得一个比较好得超参数结果。在模型参数步长输入中，发现在输入步长设置为实验数据长度 N 时，模型表现出来的性能最好。因此，模型超参数的优化部分为隐藏神经元的数量。对于模型训练权重初始化有两种方法：标准正太分布、截断正太分布。为了对模型的参数调整更好，实验采用验证方法是交叉验证方法^[75]，对模型性能进行评估。实验将数据分为 6 组，每个每组单独进行试验。将其中的 5 组数据做验证集，将多次验证集中模拟结果进行相加并取平均值，通过计算获得交叉验证误差。

模型的初始化权重的分配是随机的，为减少随机带来的误差，每次试验都进行了多次的训练，取误差较好的超参数进行设置。以下为交叉试验验证的训练结果：

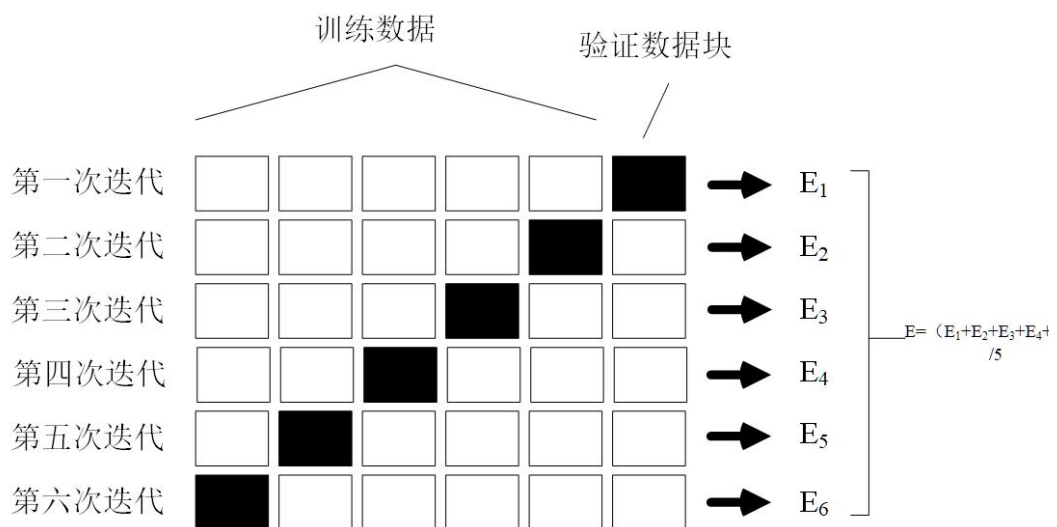


图 6.8 交叉验证法

6.4 LAI 预测精准度分析

油菜在出苗到返青时期，LAI 数值在缓步提升，油菜到花期，LAI 的增长速率会下降，在成熟后 LAI 会呈现一个递减的过程。本次试验采用的数据是 2014 到 2019 年的湖北省 7 个气象站点附近的油菜 LAI 日变化数据。共 $7 \times 6 \times 150$ 条

LAI数据, 6*7条LAI时序曲线。试验的验证集为2020年的7条LAI时序曲线。

将单一条验证数据集划分为多个40天的LAI曲线数据集, 在40天的数据集中, 前20天作为模型的输入数据, 后20天为标签数据作为预测数据的对比参数标签。结果显示LAI预测值的精准度较高, 油菜LAI在出苗到返青时期的精准度误差比花期的LAI精准度差一点。预测油菜花期LAI与标签LAI的RMSE小于0.1; 预测油菜出苗到返青时期LAI与标签LAI的RMSE小于0.15; 预测油菜成熟期LAI与标签LAI的RMSE小于0.2。实验结果如下2图所示(图6.9、图6.10)所示;




图 6.9 油菜 135-155 预测数据比对结果图




图 6.10 油菜 135-155 预测数据比对结果图

6.5 本章小结

本章是对油菜生长 LAI 时序曲线的生长预测模型长短期记忆神经网络（LSTM）的介绍。在文章的开始对 LSTM 演化而来的过程进行了简述，通过循环神经网络在时序数据处理上的弊端说明了长短期记忆神经网络（LSTM）的重要性。本章对长短期记忆神经网络（LSTM）模型的关键问题进行了详细的阐述，长短期记忆神经网络（LSTM）在长期依赖问题上的解决方式。本章结尾处介绍了长短期记忆神经网络（LSTM）在油菜 LAI 预测领域上的应用，以及对油菜 LAI 预测结果进行了分析。实验表明长短期记忆神经网络（LSTM）在油菜 LAI 时序曲线预测上有这较高的精准度。对油菜生长状态调节以及对油菜的产量预测都有着不小的作用。

第 7 章 总结和展望

7.1 本文工作总结

在本研究中，我们开发了一个能够实现大区域尺度的油菜估产算法，结合遥感数据和气象数据，利用 WOFOST 模型，通过遥感数据同化，模拟油菜生长过程中的 LAI 变化曲线，提取作物关键生育期的 LAI，弥补在大区域尺度数据的不足。在地面实验中我们发现抽薹期和花期的综合 LAI 能够实现提前、较准确地油菜产量预估。通过利用 GF-1 WFV 数据构建的 LAI 反演模型能够将 LAI 作为中间量实现大范围尺度的油菜估产。我们测试了几种常用的植被指数后发现在抽薹期 SR 植被指数与 LAI 相关性最好。然而在花期由于冠层出现花的原因， $VARI_{green}$ 植被指数与 LAI 相关性最优。最终利用覆盖油菜抽薹期和花期的 GF-1 WFV 数据，高精度的分类结果能够支持我们对油菜大范围产量估测估测。

为了验证估产算法的有效性和鲁棒性我们在阳新县和武穴市进行了实验，利用高分数据，选择金字塔瓶颈残差网络作为分类方法，对阳新县 2015-2020、武穴市 2014-2020 油菜面积进行提取，之后运用本研究算法估算阳新县、武穴市每年的油菜总产量。实验结果表明，采用本研究的估产算法结果与统计年鉴的相比，误差低于 6%，表明该算法在实现大区域尺度油菜估产具有很强的潜力。未来，我们将利用更多遥感数据（Sentinel-2、GF-2），对更多的区域（湖北省其他地市、其他省市）进行算法的测试及优化，基于多源遥感数据实现高精度、大区域的油菜估产，为我国粮食估产领域提供新的技术支撑。

7.2 未来工作展望

随着遥感技术的不断提升，农业技术瓶颈的产生。农业遥感成为了新欣方向，结合遥感对农业的辅助，虽然能够实现过往从未有过的技术新突破，但是在实际的操作过程中，现今任然还有着众多的难题难以解决，有很多的方面值得我们进一步探索下去。

(1) 不同遥感卫星空间分辨率差异过大，遥感数据影像数据被环境过于影像，导致图像不清晰，云层、雾霾的影响以及部分卫星拍摄角度带来的影响，可用数据匮乏。尽管可以对图像进行筛选剔除，但数据量的匮乏依旧限制了实验的进行。对于农业研究来说各植被指数受图像质量所影响，且在地类分类上图像质量也直接关联分类结果。希望以后图像的处理上有这新技术的突破，解决图像数据不理想的问题。

(2) 作物生长的模拟也仅代表这符合实际生长的一定趋势，本文使用的WOFOST模型虽然模拟LAI数据接近油菜的真实生长LAI，但终极是模拟数据，在一定程度上无法具有很强的说服力。如果能针对这一问题进行设置实时传感器对作物的生长过程进行全程检测，以及对作物生长环境的各项数据进行实时检测分析，实时数据的不断提取，或许能够进一步对实验进行加强，使得实验结果更为精准且更居说服力。

(3) 就目前来说产量估测有着一定的成就，但也应该对产量的提升进行研究，结合第三章我们可以得知作物生长的过程是可以进行预测的，在以预知作物接下来的生长状态情况下如何对作物的生长环境及护理是一个新的研究方向。作物的有效护理能够对作物的产量进行拔高。这也是本文工作接下来需要研究的一个重要方向。

致 谢

铃铃铛铛的，自我走进南昌大学后三年已经快要过去了。在 2019 年踏入校园时，我觉得三年太长，长到觉得这会是半生，但是转眼如今已是 2022 年，我却又感觉时间过的太快，快到仿佛我才刚刚进校园，转眼又要离开了。我还有好多好多的事情没有去做，校园我还有很多地方我没有去过。但终究三年快要结束了，在这三年我也变成了一个相对还可以的人了。三年中，我从一个茫茫的学生变成了一个拥有自己成果的研究生，我衷心的感谢培养我的南昌大学以及认真培养我的导师们。

在此，我要感谢我的学校，南昌大学，在这优美的校园里我能够结实到众多的可爱的人们，导师们、同实验室的伙伴们、同班同学、室友们。每一位都是这这三年生活的点滴。生活也是从他们身上开始的。

再有，我要感谢我的导师们，唐荣欣研究员和汤文超老师以及魏静波副辅导员，感谢三位导师在这三年生活以及学习上的照顾以及教导。从迷茫的开始科研任务到最后的独立完成任务是导师们手把手教导出来的。毕业论文的题目方向选择，实验设计以及实验的验证，最后是写完论文后导师的修改润色都是在导师们的不断指引下完成的，导师们一丝不苟的学术态度以及对实验的严谨都是我需要学习的，这三年也是我不断学习的过程是受益终身的三年。

再有，我要感谢南昌大学空间科学与技术研究院遥感组这个可爱的实验组，组内成员虽然不是新人但胜似亲人；在此感谢我的同门曹昌浩同学、黄志文同学、麻姚斌同学。在进入遥感组的开始就没有离开师兄们的照顾，在此感谢我的师兄们，李奇泽、刘华霖、何超奇、陈杜、曹凯。他们都是可爱的人。

在最后，我还有对我的父母亲表达无尽的感谢，从我呱呱落地的瞬间到抚育我至今，无论我做的如何他们都能够给予包容，在我失败的时候给我鼓励，让我再接再厉，在我出成果时告诫我要戒骄戒躁不要高傲。在此我想说爸妈您们辛苦了，往后余生请让我来为你们撑开保护伞。

最后，感谢各位参与我论文评审和答辩的老师专家们。

郭涛
2022 年 3 月

参考文献

- [1] 宁允祯. 做好粮食价格的宏观调控工作 [J]. 商业时代, 1993, (11): 52-21.
- [2] 王丹. 促进农村果业发展助力乡村振兴 [J]. 对外经贸, 2019, (9): 44-59.
- [3] SOLA-GUIRADO R R, CASTILLO-RUIZ F J, JIMÉNEZ-JIMÉNEZ F, et al. Olive actual “on year” yield forecast tool based on the tree canopy geometry using UAS imagery [J]. Sensors (Basel, Switzerland), 2017, 17(8): 1743.
- [4] JIAN-YING L I, JIANG-YU M A O. Experimental 15-day-lead statistical forecast of intraseasonal summer monsoon rainfall over Eastern China [J]. Atmospheric and oceanic science letters = Daqi-he-haiyang-kexue-kuaibao, 2016, 9(1): 66-73.
- [5] TAUBMAN B F, HAINS J C, THOMPSON A M, et al. Aircraft vertical profiles of trace gas and aerosol pollution over the mid-Atlantic United States: Statistics and meteorological cluster analysis [J]. Journal of Geophysical Research Atmospheres, 2006, 111(10).
- [6] 钱永兰 侯英雨 延昊 毛留喜 吴门新 何. 基于遥感的国外作物长势监测与产量趋势估计 [J]. Nong ye gong cheng xue bao, 2012, 28(13): 166-71.
- [7] 强化科技国际交流 促进农业增效——加拿大专家托马斯先生来临洮县指导油菜生产技术 [J]. 定西科技, 2012, (3): 33-.
- [8] ULLAH A. 巴基斯坦桃生产的经济学分析 [D]; 西北农林科技大学, 2018.
- [9] 朱艳, 汤亮, 刘蕾蕾, et al. 作物生长模型(CropGrow)研究进展 [J]. Chung-kuo nung yeh k'o hsueh, 2020, 53(16): 3235-56.
- [10] DORIGO W A, ZURITA-MILLA R, DE WIT A J W, et al. A review on reflective remote sensing and data assimilation techniques for enhanced agroecosystem modeling [J]. International Journal of Applied Earth Observation and Geoinformation, 2007, 9(2): 165-93.
- [11] PANTAZI X E, MOSHOU D, ALEXANDRIDIS T, et al. Wheat yield prediction using machine learning and advanced sensing techniques [J]. Computers and Electronics in Agriculture, 2016, 121: 57-65.
- [12] YAO S, CHEN Y, TIAN X, et al. Pneumonia Detection Using an Improved Algorithm Based on Faster R-CNN [J]. Comput Math Methods Med, 2021, 2021: 8854892.
- [13] WITTKOP B, SNOWDON R J, FRIEDT W. Status and perspectives of breeding for enhanced yield and quality of oilseed crops for Europe [J]. Euphytica, 2009, 170(1-2): 131-40.
- [14] LI T, ANGELES O, MARCAIDA M, et al. From ORYZA2000 to ORYZA (v3): An improved simulation model for rice in drought and nitrogen-deficient environments [J]. Agricultural and forest meteorology, 2017, 237-238: 246-56.
- [15] HOLZWORTH D P, HUTH N I, DEVOIL P G, et al. APSIM – Evolution towards a new

参考文献

- generation of agricultural systems simulation [J]. Environmental modelling & software : with environment data news, 2014, 62: 327-50.
- [16] DU M, NOGUCHI N. Monitoring of wheat growth status and mapping of wheat yield's within-field spatial variations using color images acquired from UAV-camera System [J]. Remote sensing (Basel, Switzerland), 2017, 9(3): 289.
- [17] 张立元, 牛亚晓, 韩文霆, et al. 大田玉米水分胁迫指数经验模型建立方法 [J]. 农业机械学报, 2018, 49(5): 233-9.
- [18] 赵文亮 贺振 贺俊平 朱. 基于 MODIS—NDVI 的河南省冬小麦产量遥感估测 [J]. Di li yan jiu, 2012, 31(12): 2310-20.
- [19] 吴琼 齐波 赵团结 姚鑫锋 朱艳 盖. 高光谱遥感估测大豆冠层生长和籽粒产量的探讨 [J]. Zuo wu xue bao, 2013, 39(2): 309-18.
- [20] MAREMA A, ARIZA M, MARTINEZ E, et al. Analysis of Vegetation Indices to Determine Nitrogen Application and Yield Prediction in Maize (*Zea mays* L.) from a Standard UAV Service (vol 9, 648, 2017) [J]. Remote sensing (Basel, Switzerland), 2018, 10(3).
- [21] 潘海珠. 基于作物多模型遥感数据同化的区域冬小麦生长模拟研究 [D]; 中国农业科学院, 2020.
- [22] LI-LI Z, SHU-HUA L, ZHI-MIN W, et al. A simulation of winter wheat crop responses to irrigation management using CERES-Wheat model in the North China Plain [J]. Journal of Integrative Agriculture, 2018, 17(5): 1181-93.
- [23] ZHAO Y, MAO X, SHUKLA M K. A modified SWAP model for soil water and heat dynamics and seed-maize growth under film mulching [J]. Agricultural and forest meteorology, 2020, 292-293: 108127.
- [24] ZHAO Z-L, LI B, FENG X, et al. Parameter estimation and verification of DSSAT-CROPGRO-Tomato model under different irrigation levels in greenhouse [J]. Ying yong sheng tai xue bao, 2018, 29(6): 2017-27.
- [25] 蒙继华 程. 作物单产估算模型研究进展与展望 [J]. 中国生态农业学报, 2015, 23(4): 402-15.
- [26] SUN L-L, HOU Q, MA Y-P, et al. Adaptability of WOFOST model to simulate the whole growth period of maize in hetao irrigation region of inner mongolia [J]. Sheng tai xue za zhi, 2016, 35(3): 800-7.
- [27] EITZINGER J, TRNKA M, HÖSCH J, et al. Comparison of CERES, WOFOST and SWAP models in simulating soil water content during growing season under different soil conditions [J]. Ecological modelling, 2004, 171(3): 223-46.
- [28] EITZINGER J, THALER S, SCHMID E, et al. Sensitivities of crop models to extreme weather conditions during flowering period demonstrated for maize and winter wheat in Austria [J]. The Journal of agricultural science, 2013, 151(6): 813-35.
- [29] ANONYMOUS. Peer review report 2 on "Assimilating a synthetic Kalman filter leaf area index series into the WOFOST model to improve regional winter wheat yield estimation"

参考文献

- [J]. Agricultural and forest meteorology, 2015, 201: 664-.
- [30] ZHANG G, PERRIE W, ZHANG B, et al. Semi-empirical ocean surface model for compact-polarimetry mode SAR of RADARSAT Constellation Mission [J]. Remote sensing of environment, 2018, 217: 52-60.
- [31] BOGUSLAVSKII I A, KRUGLYAKOVA O V, MIROSHICHEV N Y, et al. Algorithm for identifying parameters of the dynamic system of an aircraft [J]. Journal of computer & systems sciences international, 2009, 48(3): 333-44.
- [32] 王修信 王. 多植被指数组合的冬小麦遥感估产方法研究 [J]. Gan han qu zi yuan yu huan jing, 2017, 31(7): 44-9.
- [33] ZHANG X, ZHANG Q. Monitoring interannual variation in global crop yield using long-term AVHRR and MODIS observations [J]. ISPRS J Photogramm Remote Sens, 2016, 114: 191-205.
- [34] 支贵良 张 林 卢 汤. 小麦光谱特性与估产模式的研究——遥感估产研究之一 [M]. 北京, 1982.
- [35] "六五" 计划讲话 [M]. 北京: 经济科学出版社, 1983.
- [36] 裘鹏霄. 充分运用农业气候资源大力开展气象科技扶贫 [J]. 浙江气象, 1989, (3): 52-3.
- [37] 侯英雨, 何亮, 靳宁, et al. 中国作物生长模拟监测系统构建及应用 [J]. Nong ye gong cheng xue bao, 2018, 34(21): 165-封 4.
- [38] KOETZ B, BARET F, POILVÉ H, et al. Use of coupled canopy structure dynamic and radiative transfer models to estimate biophysical canopy characteristics [J]. Remote Sensing of Environment, 2005, 95(1): 115-24.
- [39] 戴聚岭. 多项式插值法在工程计算中应用 [J]. 福建电脑, 2006, (4): 178-9.
- [40] 邱敏 陈鸣渊 罗潋葱 李慧赟 戴. 松花湖地区日总辐射计算模型的参数估算 [J]. 生态与农村环境学报, 2017, 33(5): 474-80.
- [41] 陆其峰, 徐一树, 吴春强, et al. 红外高光谱干涉仪辐射定标误差敏感性因子的仿真分析 [J]. Guang xue, jing mi gong cheng, 2020, 28(4): 867-77.
- [42] 张晓月, 李琳琳, 王莹, et al. 采用 Landsat8 产品算法流程的高分一号数据大气校正 [J]. Nong ye gong cheng xue bao, 2020, 36(1): 182-92.
- [43] 么鸿原, 王海鹏, 林雪原, et al. 遥感图像拼接中改进的图像预处理算法研究 [J]. 计算机与数字工程, 2020, 48(2): 428-32.
- [44] PESCHECHERA G, NOVELLI A, CARADONNA G, et al. Calibration of the CLAIR model by using landsat 8 surface reflectance higher-level data and MODIS leaf area index products, F 2017].
- [45] ZUO C, CHEN Q, YU Y, et al. Transport-of-intensity phase imaging using Savitzky-Golay differentiation filter-theory and applications [J]. Optics express, 2013, 21(5): 5346-62.
- [46] LORIEUL T, PEARSON K D, ELLWOOD E R, et al. Toward a large-scale and deep phenological stage annotation of herbarium specimens: Case studies from temperate, tropical, and equatorial floras [J]. Applications in plant sciences, 2019, 7(3): e01233-n/a.

参考文献

- [47] CONNOLLY R D. Modelling effects of soil structure on the water balance of soil-crop systems: a review [J]. Soil & tillage research, 1998, 48(1): 1-19.
- [48] 陈锡龙 罗文文 韩明玉 杨. 纺锤形苹果树冠层不同区位叶片光合有效辐射积累与叶片质量关系的研究 [J]. Guoshu xuebao = Journal of fruit science, 2013, 30(6): 952-7.
- [49] 杨贺. 日光温室冬春季不同种植密度番茄植株群体光分布特性和冠层结构的研究 [D]; 沈阳农业大学, 2007.
- [50] 苏李君, 刘云鹤, 王全九. 基于有效积温的中国水稻生长模型的构建 [J]. Nong ye gong cheng xue bao, 2020, 36(1): 162-74.
- [51] 肖悦岩 渡. 根据日最高、最低气温计算有效积温的简便方法 [J]. 中国植保导刊, 1981, (2): 39-44.
- [52] Effects of water-nitrogen combination on dry matter, nitrogen accumulation and yield of winter wheat [J]. Ying yong sheng tai xue bao, 2020, 31(8): 2593-603.
- [53] CURTIS P S, VOGEL C S, PREGITZER K S, et al. Interacting effects of soil fertility and atmospheric CO₂ on leaf area growth and carbon gain physiology in *Populus x euramericana* (Dode) Guinier [J]. The New phytologist, 1995, 129(2): 253-63.
- [54] BUSETTO L, RANGHETTI L. MODISStp: An R package for automatic preprocessing of MODIS Land Products time series [J]. Computers & geosciences, 2016, 97: 40-8.
- [55] 金晶. 多/高光谱遥感图像光谱分解研究与应用 [D]; 复旦大学, 2010.
- [56] BERNABE S, MARPU P R, PLAZA A, et al. Spectral-Spatial Classification of Multispectral Images Using Kernel Feature Space Representation [J]. IEEE geoscience and remote sensing letters, 2014, 11(1): 288-92.
- [57] TEFFAHI H. 高光谱和多光谱图像分类的谱-空间特征提取技术 [D]; 哈尔滨工业大学, 2018.
- [58] BAHARI N I S, AHMAD A, ABOOBAIDER B M. Application of support vector machine for classification of multispectral data, Bristol, F 2014]. IOP Publishing.
- [59] BERHANE T M, LANE C R, WU Q, et al. Decision-tree, rule-based, and random forest classification of high-resolution multispectral imagery for wetland mapping and inventory [J]. Remote sensing (Basel, Switzerland), 2018, 10(4): 580-.
- [60] WANG Y-H, CHEN E-X, GUO Y, et al. Deep U-net Optimization Method for Forest Type Classification with High Resolution Multispectral Remote Sensing Images [J]. Forest research (Beijing), 2020, 33(1): 11-8.
- [61] LIANG S, CHENG J, ZHANG J. Maximum likelihood classification of soil remote sensing image based on deep learning [J]. Earth sciences research journal, 2020, 24(3): 348-56.
- [62] LIU J, ZHANG C, WAN S. The Classification Method of Multi-spectral Remote Sensing Images Based on Self-adaptive Minimum Distance Adjustment [M]. Computer and Computing Technologies in Agriculture VI. Berlin, Heidelberg; Springer Berlin Heidelberg. 2013: 430-7.
- [63] HINTON G E, SRIVASTAVA N, KRIZHEVSKY A, et al. Improving neural networks by

参考文献

- preventing co-adaptation of feature detectors [J]. 2012.
- [64] LU Z, XU B, SUN L, et al. 3-D Channel and Spatial Attention Based Multiscale Spatial-Spectral Residual Network for Hyperspectral Image Classification [J]. IEEE journal of selected topics in applied earth observations and remote sensing, 2020, 13: 4311-24.
- [65] PAOLETTI M E, HAUT J M, FERNANDEZ-BELTRAN R, et al. Deep Pyramidal Residual Networks for Spectral-Spatial Hyperspectral Image Classification [J]. IEEE transactions on geoscience and remote sensing, 2019, 57(2): 740-54.
- [66] WUNSCH A, LIESCH T, BRODA S. Groundwater level forecasting with artificial neural networks: A comparison of long short-term memory (LSTM), convolutional neural networks (CNNs), and non-linear autoregressive networks with exogenous input (NARX) [J]. Hydrology and earth system sciences, 2021, 25(3): 1671-87.
- [67] 张金磊, 罗玉玲, 付强. 基于门控循环单元神经网络的金融时间序列预测 [J]. 广西师范大学学报 (自然科学版), 2019, 37(2): 82-9.
- [68] CHEN M, LI W-Z, QIAN L, et al. Next POI Recommendation Based on Location Interest Mining with Recurrent Neural Networks [J]. Journal of computer science and technology, 2020, 35(3): 603-16.
- [69] MOHAMED C, NSIRI B, ABDELMAJID S, et al. Deep Convolutional Networks for Image Segmentation: Application to Optic Disc detection, F 2020]. IEEE.
- [70] 黄锦柳. 工业时间序列数据预测方法研究 [D]; 杭州电子科技大学, 2020.
- [71] LIANGHUA H E, GUANYU C A I. Regularization-based method for solving problem of gradient disappearance of adversarial residual transform network. 2020-..
- [72] JIANG S, FANG S-C, NIE T, et al. A gradient descent based algorithm for $l(p)$ minimization [J]. European journal of operational research, 2020, 283(1): 47-56.
- [73] 谭方颖, 郭安红, 宋迎波, et al. 2019 年夏收粮油作物生育期气象条件及其影响分析 [J]. Zhongguo nongye qixiang, 2019, 40(9): 603-6.
- [74] CHAOCHAO C, LI W, LONGFEI Z, et al. Multi-party joint training method and system based on Adam optimization algorithm. 2020-..
- [75] 王瑞波. 监督学习算法预测性能比较的正则化交叉验证方法研究 [D]; 山西大学, 2019.

攻读学位期间的研究成果

1. 郭涛、汤文超、魏静波，《WOFOST 模型与遥感数据同化的油菜估产方法研究》 中文核心
2. 汤文超、魏静波、唐荣欣、郭涛，《Remote Prediction of Oilseed Yield with Ganfen-1 Image and Crop Model》，SCI 二区